LAPORAN TUGAS
KLASIFIKASI NAIVE BAYES & SVM

Mata Kuliah Machine Learning – Pertemuan 8

Kelas : TI-C5 | Kelompok : 5

Anggota Kelompok:
1. Muhammad Irfan Nuha (434241079)
2. Bunga Lala Sal Sabila (434241066)

Tugas Kelompok

---

1. Pendahuluan

Tugas ini melanjutkan UTS kelompok kami. Dataset dan seluruh tahapan dibuat **sama dengan UTS**: dataset *Airline Passenger Satisfaction* (103.904 data penumpang) diproses melalui preprocessing, transformasi Min-Max, split 80% training dan 20% testing, serta seleksi fitur Chi-Square dan ANOVA F. Bedanya, kali ini klasifikasi dilakukan dengan **Naive Bayes** dan **SVM**, lalu hasilnya dibandingkan dengan **Decision Tree** dari UTS. Metode dengan akurasi tertinggi kemudian dibuatkan antarmuka (UI) berbasis **Streamlit** sehingga bisa dipakai untuk memprediksi kepuasan penumpang secara langsung.

2. Metode Klasifikasi

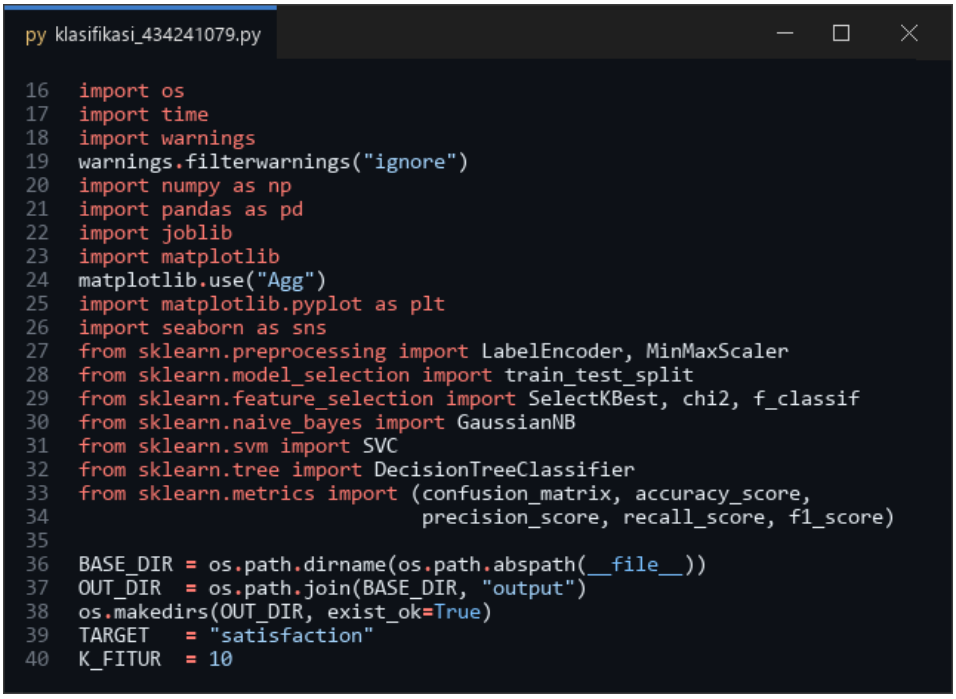
Naive Bayes (GaussianNB) menghitung peluang sebuah data masuk ke tiap kelas memakai Teorema Bayes, lalu memilih kelas dengan peluang terbesar. Disebut *naive* karena menganggap semua fitur saling independen, dan versi Gaussian mengasumsikan tiap fitur numerik berdistribusi normal. Metode ini sangat cepat, tetapi asumsinya jarang terpenuhi sempurna di data nyata.

SVM (Support Vector Machine) mencari *hyperplane* pemisah dua kelas dengan margin selebar mungkin. Dengan **kernel RBF**, data dipetakan ke ruang berdimensi lebih tinggi sehingga SVM mampu membentuk batas keputusan yang melengkung (non-linear). Kelemahannya, waktu pelatihan bertambah cepat seiring banyaknya data.

Decision Tree (dari UTS) membagi data secara bertahap berdasarkan aturan if-else pada fitur, membentuk struktur pohon. Model ini mudah ditafsirkan namun rawan *overfitting*.

3. Tahapan Program (Sama dengan UTS)

Program utama adalah **klasifikasi_434241079.py**. Berikut library dan konfigurasi yang dipakai:



Kode 1. Import library dan konfigurasi

Bagian awal program identik dengan UTS. Data dibaca, kolom *id* dibuang, lalu dilakukan deteksi dan handling **missing value** (310 sel kosong di *Arrival Delay in Minutes* diisi median), pengecekan **duplikasi** (tidak ada), dan **capping outlier** dengan metode IQR. Kolom kategorikal di-encode menjadi angka, kemudian seluruh fitur dinormalisasi **Min-Max** ke rentang [0, 1] dan dibagi **80% training (83.123 data) : 20% testing (20.781 data)** secara stratified.

py klasifikasi_434241079.py

```python
    # ---------------- 1. INPUT ----------------
    garis("1. INPUT DATA")
    df = pd.read_csv(os.path.join(BASE_DIR, "train.csv"))
    df.columns = df.columns.str.strip()
    df = df.drop(columns=[c for c in ["Unnamed: 0", "id"] if c in df.columns])
    print(f"Ukuran data : {df.shape[0]} baris x {df.shape[1]} kolom")
    print(df.iloc[:5, :6].to_string(index=False))
    print(f"... (+{df.shape[1] - 6} kolom lainnya)")

    # ---------------- 2. PREPROCESSING ----------------
    garis("2. PREPROCESSING")
    miss = df.isna().sum()
    print(f">> Missing value : {int(miss.sum())} sel "
          f"({', '.join(f'{k}={v}' for k, v in miss[miss > 0].items()) or '-'})")
    for c in df.select_dtypes(include=[np.number]).columns:
        df[c] = df[c].fillna(df[c].median())
    for c in df.select_dtypes(include="object").columns:
        df[c] = df[c].fillna(df[c].mode()[0])

    dup = int(df.duplicated().sum())
    print(f">> Duplikasi     : {dup} baris")
    df = df.drop_duplicates().reset_index(drop=True)

    kol_num = [c for c in df.select_dtypes(include=[np.number]).columns
               if df[c].nunique() > 15]
    Q1, Q3 = df[kol_num].quantile(0.25), df[kol_num].quantile(0.75)
    IQR = Q3 - Q1
    batas = {c: (Q1[c] - 1.5 * IQR[c], Q3[c] + 1.5 * IQR[c]) for c in kol_num}
    for c in kol_num:
        df[c] = np.clip(df[c], *batas[c])
    print(f">> Outlier       : di-capping IQR pada {len(kol_num)} kolom numerik")

    encoder = {}
    for c in df.select_dtypes(include="object").columns:
        le = LabelEncoder()
        df[c] = le.fit_transform(df[c])
        encoder[c] = list(le.classes_)
    label = encoder[TARGET]
    print(f">> Encoding      : {[c for c in encoder if c != TARGET]}")
    print(f">> Target        : 0 = {label[0]} ({(df[TARGET] == 0).sum()}), "
          f"1 = {label[1]} ({(df[TARGET] == 1).sum()})")

    X = df.drop(columns=[TARGET])
    y = df[TARGET]
```

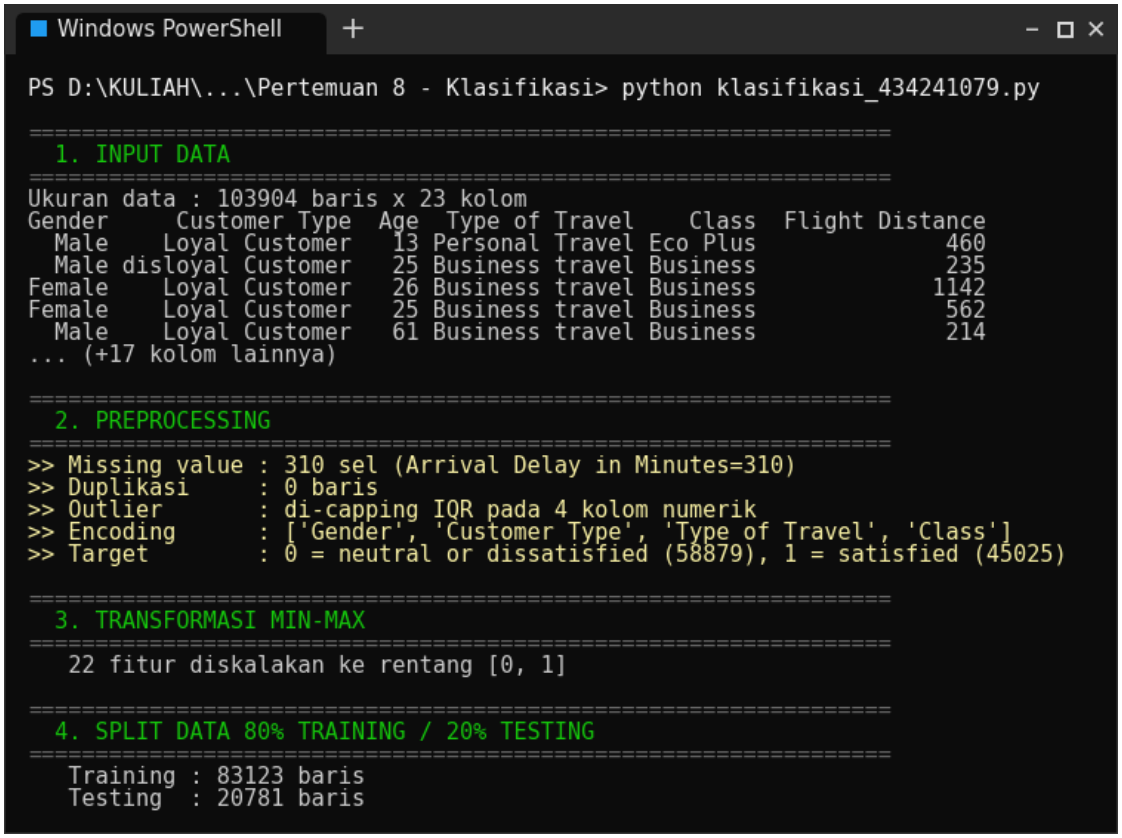
Kode 2. Input data dan preprocessing

py klasifikasi_434241079.py

```python
    # ---------------- 3. TRANSFORMASI ----------------
    garis("3. TRANSFORMASI MIN-MAX")
    scaler = MinMaxScaler()
    X_scaled = pd.DataFrame(scaler.fit_transform(X), columns=X.columns)
    print(f"   {X.shape[1]} fitur diskalakan ke rentang "
          f"[{X_scaled.values.min():.0f}, {X_scaled.values.max():.0f}]")

    # ---------------- 4. SPLIT ----------------
    garis("4. SPLIT DATA 80% TRAINING / 20% TESTING")
    X_train, X_test, y_train, y_test = train_test_split(
        X_scaled, y, test_size=0.20, random_state=42, stratify=y)
    print(f"   Training : {len(X_train)} baris")
    print(f"   Testing  : {len(X_test)} baris")
```

Kode 3. Transformasi Min-Max dan split 80/20



Output tahap input, preprocessing, transformasi, dan split

4. Klasifikasi Naive Bayes, SVM, dan Decision Tree

Inti tugas ada di perulangan berikut. Untuk tiap metode seleksi fitur (Chi-Square dan ANOVA F), dipilih 10 fitur teratas, lalu tiga model dilatih pada data training yang sama: **GaussianNB**, **SVC (kernel RBF)**, dan **DecisionTreeClassifier**. Waktu pelatihan dicatat, kemudian setiap model dievaluasi pada data testing melalui fungsi *evaluasi()* yang menghitung confusion matrix, akurasi, presisi, recall, dan F1-Score, sekaligus menyimpan gambar confusion matrix.

py klasifikasi_434241079.py

```python
    # ---------------- 5-7. SELEKSI FITUR + KLASIFIKASI + EVALUASI ----------------
    semua_hasil, model_terlatih = [], {}
    for nama_seleksi, fungsi in [("Chi-Square", chi2), ("ANOVA F", f_classif)]:
        garis(f"5. SELEKSI FITUR: {nama_seleksi} ({K_FITUR} fitur teratas)")
        selector = SelectKBest(score_func=fungsi, k=K_FITUR).fit(X_train, y_train)
        fitur = X_train.columns[selector.get_support()].tolist()
        for f in fitur:
            print(f"   - {f}")
        Xtr, Xte = selector.transform(X_train), selector.transform(X_test)

        garis(f"6. KLASIFIKASI & EVALUASI (fitur {nama_seleksi})")
        daftar_model = {
            "Naive Bayes": GaussianNB(),
            "SVM": SVC(kernel="rbf", random_state=42, cache_size=1000),
            "Decision Tree": DecisionTreeClassifier(random_state=42),
        }
        for nama_model, model in daftar_model.items():
            if nama_model == "SVM":
                print(f">> {nama_model} sedang dilatih (bisa 2-3 menit)...")
            mulai = time.time()
            model.fit(Xtr, y_train)
            durasi = time.time() - mulai
            nama = f"{nama_model} + {nama_seleksi}"
            print(f">> {nama}  (waktu latih {durasi:.1f} detik)")
            hasil = evaluasi(nama, y_test, model.predict(Xte), label)
            hasil["Waktu (detik)"] = round(durasi, 1)
            semua_hasil.append(hasil)
            model_terlatih[nama] = (model, selector, fitur)
```

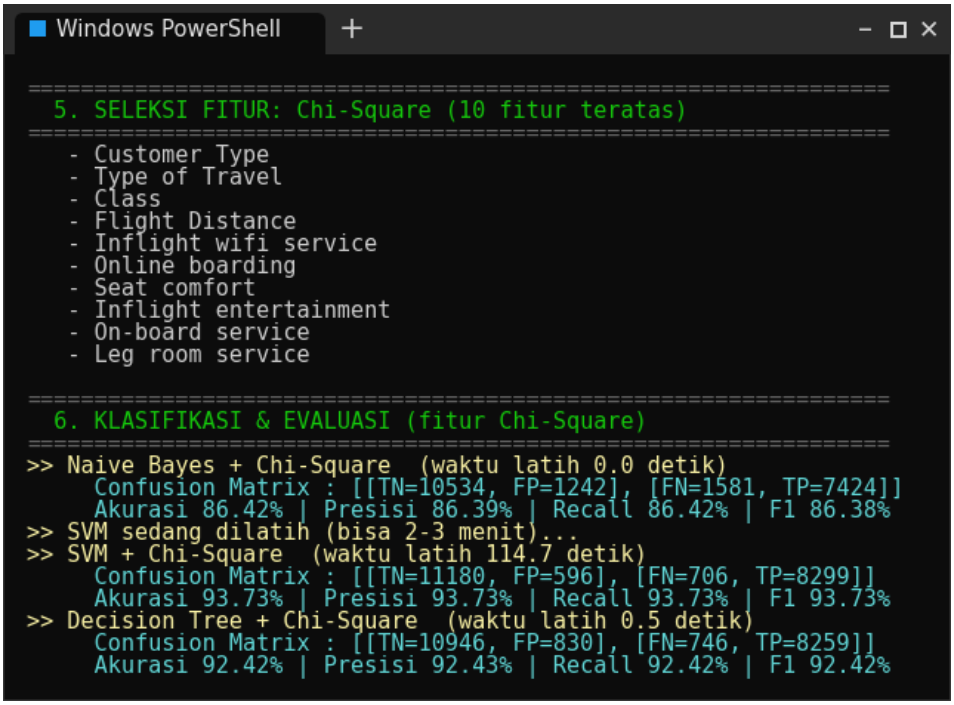
Kode 4. Seleksi fitur dan pelatihan tiga model

py klasifikasi_434241079.py

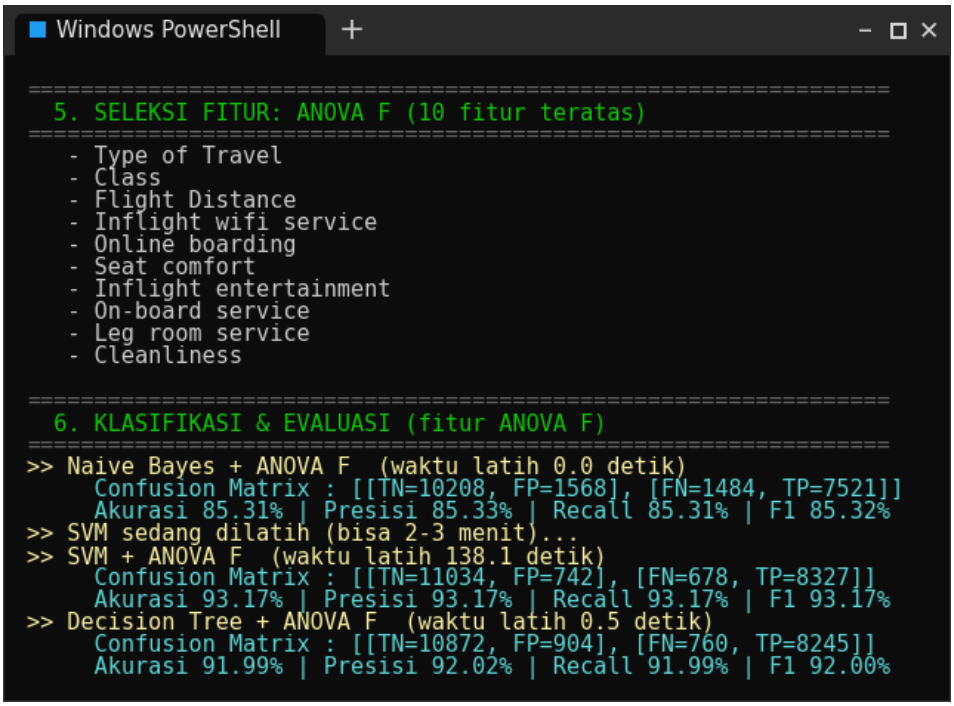
```python
def evaluasi(nama, y_test, y_pred, label):
    """Hitung confusion matrix + metrik, cetak, dan simpan gambar CM."""
    cm = confusion_matrix(y_test, y_pred)
    tn, fp, fn, tp = cm.ravel()
    hasil = {
        "Model": nama,
        "Akurasi": accuracy_score(y_test, y_pred),
        "Presisi": precision_score(y_test, y_pred, average="weighted"),
        "Recall": recall_score(y_test, y_pred, average="weighted"),
        "F1": f1_score(y_test, y_pred, average="weighted"),
        "TN": tn, "FP": fp, "FN": fn, "TP": tp,
    }
    print(f"     Confusion Matrix : [[TN={tn}, FP={fp}], [FN={fn}, TP={tp}]]")
    print(f"     Akurasi {hasil['Akurasi']*100:.2f}% | Presisi {hasil['Presisi']*100:.2f}% | "
          f"Recall {hasil['Recall']*100:.2f}% | F1 {hasil['F1']*100:.2f}%")

    plt.figure(figsize=(4.6, 4))
    sns.heatmap(cm, annot=True, fmt="d", cmap="Blues", cbar=False,
                xticklabels=label, yticklabels=label)
    plt.xlabel("Prediksi")
    plt.ylabel("Aktual")
    plt.title(f"Confusion Matrix\n{nama}", fontsize=10)
    plt.tight_layout()
    nama_file = nama.lower().replace(" + ", "_").replace(" ", "_").replace("-", "")
    plt.savefig(os.path.join(OUT_DIR, f"cm_{nama_file}.png"), dpi=120)
    plt.close()
    return hasil
```

Kode 5. Fungsi evaluasi (confusion matrix dan metrik)

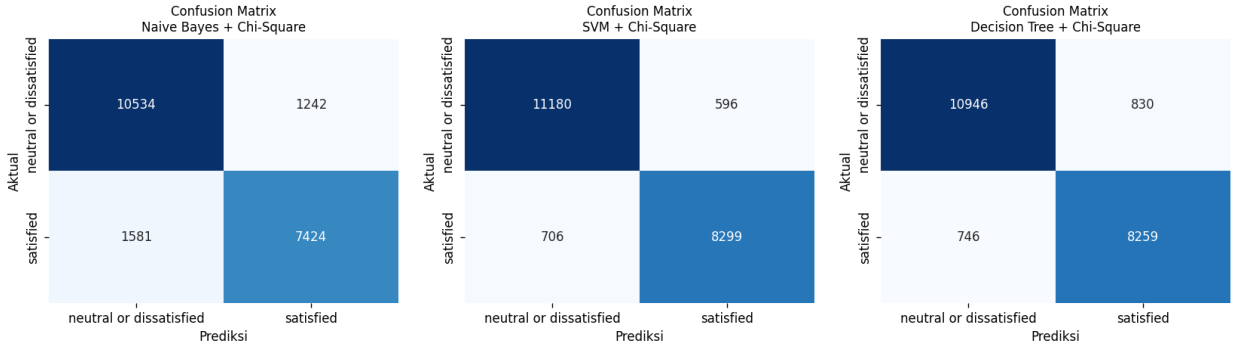


Output klasifikasi dengan fitur hasil Chi-Square



Output klasifikasi dengan fitur hasil ANOVA F

5. Analisis Confusion Matrix



Confusion matrix (seleksi Chi-Square): Naive Bayes, SVM, Decision Tree

Model	TN	FP	FN	TP	Total Salah
Naive Bayes + Chi-Square	10,534	1,242	1,581	7,424	2,823
SVM + Chi-Square	11,180	596	706	8,299	1,302
Decision Tree + Chi-Square	10,946	830	746	8,259	1,576

Tabel 1. Rincian confusion matrix (20.781 data testing)

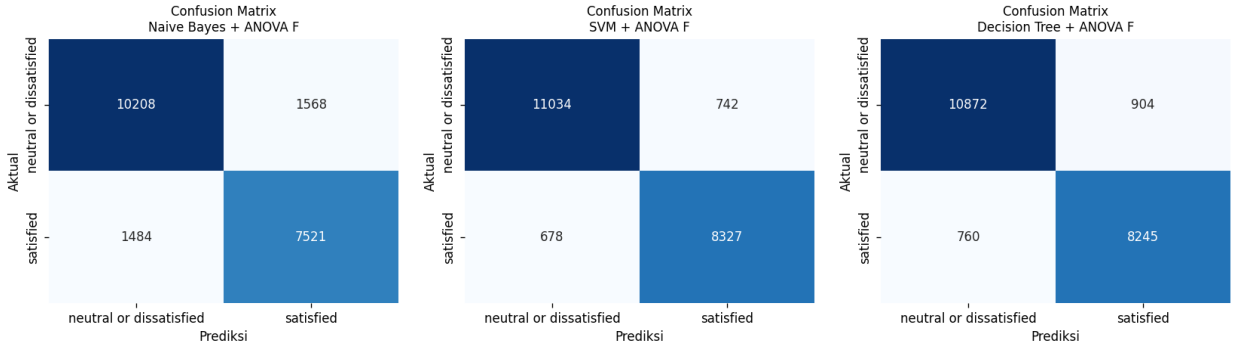
Dengan kelas positif = *satisfied*, confusion matrix dibaca sebagai: **TN** = penumpang tidak puas yang tertebak benar, **FP** = penumpang tidak puas yang salah ditebak puas, **FN** = penumpang puas yang salah ditebak tidak puas, dan **TP** = penumpang puas yang tertebak benar.

- **Naive Bayes** membuat kesalahan terbanyak, yaitu **2,823** data (1,242 FP dan 1,581 FN). Asumsi independen tidak cocok karena rating-rating layanan saling berkaitan (penumpang yang puas dengan kursi cenderung puas juga dengan hiburan), sehingga peluang yang dihitung menjadi bias.

- **SVM** paling sedikit salah: hanya **1,302** data (596 FP dan 706 FN). Kernel RBF mampu menangkap pola non-linear antar-fitur yang tidak bisa ditangkap Naive Bayes.

- **Decision Tree** berada di tengah dengan **1,576** kesalahan (830 FP dan 746 FN), sama persis dengan hasil UTS.

Pada ketiga model, kesalahan tersebar cukup seimbang antara FP dan FN, artinya tidak ada model yang condong berlebihan menebak satu kelas saja.

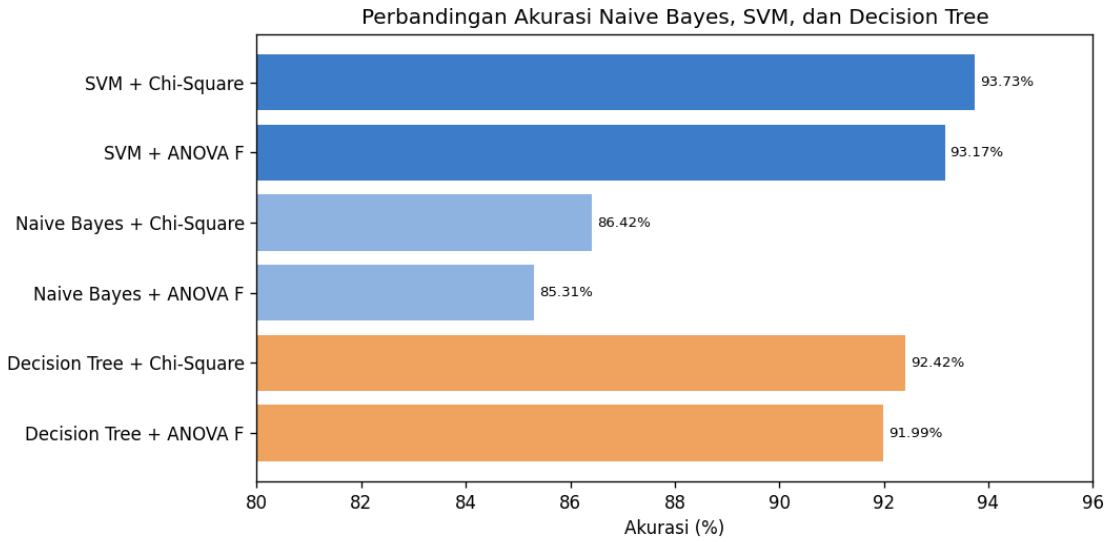


Confusion matrix (seleksi ANOVA F): Naive Bayes, SVM, Decision Tree

6. Perbandingan Kinerja

Model	Akurasi	Presisi	Recall	F1-Score	Waktu Latih
SVM + Chi-Square	93.73%	93.73%	93.73%	93.73%	114.7 s
SVM + ANOVA F	93.17%	93.17%	93.17%	93.17%	138.1 s
Decision Tree + Chi-Square	92.42%	92.43%	92.42%	92.42%	0.5 s
Decision Tree + ANOVA F	91.99%	92.02%	91.99%	92.00%	0.5 s
Naive Bayes + Chi-Square	86.42%	86.39%	86.42%	86.38%	0.0 s
Naive Bayes + ANOVA F	85.31%	85.33%	85.31%	85.32%	0.0 s

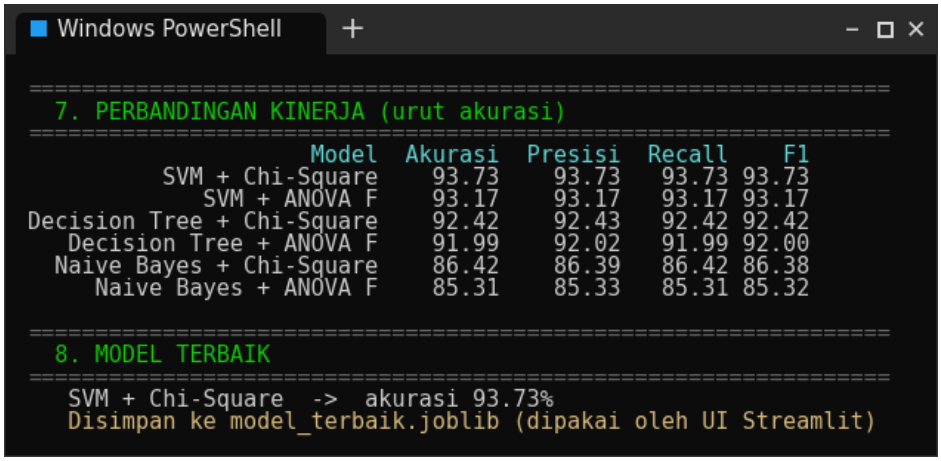
Tabel 2. Perbandingan seluruh kombinasi model dan seleksi fitur (urut akurasi)



Perbandingan akurasi ketiga metode

Urutan kinerja konsisten di kedua metode seleksi fitur: **SVM > Decision Tree > Naive Bayes**. Akurasi tertinggi diraih **SVM + Chi-Square** sebesar **93,73%**, unggul dari Decision Tree (92,42%) dan jauh di atas Naive Bayes (86,42%). Seleksi Chi-Square juga sedikit lebih baik dari ANOVA F untuk ketiga model.

Namun keunggulan SVM dibayar dengan waktu: SVM butuh sekitar **115 detik** untuk dilatih, sementara Decision Tree kurang dari 1 detik dan Naive Bayes hampir instan. Untuk data sebesar ini, Decision Tree tetap menjadi pilihan yang sangat efisien, tetapi bila yang diutamakan adalah ketepatan prediksi, SVM adalah model terbaik. Karena itu SVM + Chi-Square dipilih untuk UI.



Output perbandingan dan penyimpanan model terbaik

7. UI/UX Streamlit (Model Terbaik: SVM)

Model terbaik disimpan ke file **model_terbaik.joblib** bersama scaler, selector, encoder, dan batas outlier, sehingga UI tidak perlu melatih ulang SVM. Aplikasi **app_streamlit_434241079.py** membaca file tersebut lalu menampilkan form berisi 10 fitur hasil seleksi Chi-Square. Input dari pengguna diproses dengan urutan yang sama seperti saat pelatihan (encoding → capping → Min-Max → seleksi fitur) sebelum diprediksi oleh SVM. Hasil prediksi diperbarui otomatis setiap kali input diubah.

py klasifikasi_434241079.py

```
    # ---------------- 8. PERBANDINGAN ----------------
    garis("7. PERBANDINGAN KINERJA (urut akurasi)")
    tabel = pd.DataFrame(semua_hasil).sort_values("Akurasi", ascending=False)
    tampil = tabel[["Model", "Akurasi", "Presisi", "Recall", "F1"]].copy()
    for c in ["Akurasi", "Presisi", "Recall", "F1"]:
        tampil[c] = (tampil[c] * 100).round(2)
    print(tampil.to_string(index=False))
    tabel.to_csv(os.path.join(OUT_DIR, "perbandingan_model.csv"), index=False)

    plt.figure(figsize=(9, 4.5))
    warna = {"Naive Bayes": "#8fb3e0", "SVM": "#3d7cc9", "Decision Tree": "#f0a35e"}
    urut = tabel.sort_values("Model")
    bar = plt.barh(urut["Model"], urut["Akurasi"] * 100,
                   color=[warna[m.split(" + ")[0]] for m in urut["Model"]])
    plt.bar_label(bar, fmt="%.2f%%", padding=3, fontsize=8)
    plt.xlim(80, 96)
    plt.xlabel("Akurasi (%)")
    plt.title("Perbandingan Akurasi Naive Bayes, SVM, dan Decision Tree")
    plt.tight_layout()
    plt.savefig(os.path.join(OUT_DIR, "perbandingan_akurasi.png"), dpi=120)
    plt.close()

    # ---------------- 9. SIMPAN MODEL TERBAIK ----------------
    terbaik = tabel.iloc[0]["Model"]
    model, selector, fitur = model_terlatih[terbaik]
    bundle = {
        "nama_model": terbaik,
        "akurasi": float(tabel.iloc[0]["Akurasi"]),
        "model": model,
        "scaler": scaler,
        "selector": selector,
        "urutan_fitur": list(X.columns),
        "fitur_terpilih": fitur,
        "encoder": {k: v for k, v in encoder.items() if k != TARGET},
        "label": label,
        "default": X.median().to_dict(),
        "batas_outlier": batas,
        "rentang": {c: (float(X[c].min()), float(X[c].max())) for c in X.columns},
        "perbandingan": tampil.to_dict("records"),
    }
    joblib.dump(bundle, os.path.join(BASE_DIR, "model_terbaik.joblib"))
    garis("8. MODEL TERBAIK")
    print(f"   {terbaik}  ->  akurasi {tabel.iloc[0]['Akurasi'] * 100:.2f}%")
    print("   Disimpan ke model_terbaik.joblib (dipakai oleh UI Streamlit)")
```

Kode 6. Perbandingan dan penyimpanan model terbaik

py app_streamlit_434241079.py

```python
@st.cache_resource
def muat_model():
    return joblib.load(PATH_MODEL)


def isi_contoh(bundle, kunci):
    """Isi semua input dengan nilai contoh (disimpan di session_state)."""
    c = CONTOH[kunci]
    for f in bundle["fitur_terpilih"]:
        if f in bundle["encoder"]:
            st.session_state[f] = c["kategori"].get(f, bundle["encoder"][f][0])
        elif bundle["rentang"][f][1] <= 5:
            st.session_state[f] = c["rating"]
        else:
            lo, hi = bundle["rentang"][f]
            st.session_state[f] = float(min(max(c["angka"].get(f, (lo + hi) / 2), lo), hi))


def prediksi(bundle, masukan):
    """Ubah input menjadi baris data, lalu: capping -> Min-Max -> seleksi fitur -> model."""
    baris = dict(bundle["default"])
    for f, nilai in masukan.items():
        if f in bundle["encoder"]:
            baris[f] = bundle["encoder"][f].index(nilai)
        else:
            lo, hi = bundle["batas_outlier"].get(f, (float("-inf"), float("inf")))
            baris[f] = min(max(float(nilai), lo), hi)
    data = pd.DataFrame([baris])[bundle["urutan_fitur"]]
    data = pd.DataFrame(bundle["scaler"].transform(data), columns=bundle["urutan_fitur"])
    data = bundle["selector"].transform(data)
    kelas = int(bundle["model"].predict(data)[0])
    skor = float(bundle["model"].decision_function(data)[0]) \
        if hasattr(bundle["model"], "decision_function") else None
    return bundle["label"][kelas], skor
```

Kode 7. app_streamlit: memuat model dan fungsi prediksi

py app_streamlit_434241079.py

```python
# ====================== TAMPILAN ======================
st.set_page_config(page_title="Prediksi Kepuasan Penumpang", page_icon=":airplane:", layout="wide")

if not os.path.exists(PATH_MODEL):
    st.error("File model_terbaik.joblib belum ada. Jalankan dulu: python klasifikasi_434241079.py")
    st.stop()

bundle = muat_model()
fitur = bundle["fitur_terpilih"]

contoh_url = st.query_params.get("contoh")
if contoh_url in CONTOH and st.session_state.get("_contoh") != contoh_url:
    isi_contoh(bundle, contoh_url)
    st.session_state["_contoh"] = contoh_url

st.title(":airplane: Prediksi Kepuasan Penumpang Maskapai")
st.caption(f"Model: **{bundle['nama_model']}** · akurasi data testing "
           f"**{bundle['akurasi'] * 100:.2f}%** · Kelompok 5 TI-C5")

with st.sidebar:
    st.header("Tentang Model")
    st.write(f"Model terpilih: **{bundle['nama_model']}**")
    st.metric("Akurasi (data testing)", f"{bundle['akurasi'] * 100:.2f}%")
    st.write("Perbandingan dengan metode lain:")
    st.dataframe(pd.DataFrame(bundle["perbandingan"])[["Model", "Akurasi"]],
                 hide_index=True, width="stretch")
    st.divider()
    st.write("Isi cepat dengan contoh:")
    if st.button("Penumpang puas", icon=":material/sentiment_satisfied:", width="stretch"):
        isi_contoh(bundle, "puas")
    if st.button("Penumpang tidak puas", icon=":material/sentiment_dissatisfied:",
                 width="stretch"):
        isi_contoh(bundle, "tidak")
```

Kode 8. app_streamlit: judul dan sidebar

py app_streamlit_434241079.py

```python
kol_kiri, kol_kanan = st.columns(2, gap="large")
masukan = {}

with kol_kiri:
    st.subheader(":briefcase: Profil Perjalanan")
    for f in fitur:
        if f in bundle["encoder"]:
            pilihan = bundle["encoder"][f]
            if f not in st.session_state:
                st.session_state[f] = pilihan[0]
            masukan[f] = st.selectbox(LABEL_FITUR.get(f, f), pilihan, key=f,
                                      format_func=lambda v: LABEL_NILAI.get(v, v))
        elif bundle["rentang"][f][1] > 5:
            lo, hi = bundle["rentang"][f]
            if f not in st.session_state:
                st.session_state[f] = float(bundle["default"][f])
            masukan[f] = st.number_input(LABEL_FITUR.get(f, f), min_value=float(lo),
                                         max_value=float(hi), step=50.0, key=f)

with kol_kanan:
    st.subheader(":star: Penilaian Layanan")
    st.caption("Skala 0–5 · 0 = tidak dinilai, 1 = sangat buruk, 5 = sangat baik")
    for f in fitur:
        if f not in bundle["encoder"] and bundle["rentang"][f][1] <= 5:
            if f not in st.session_state:
                st.session_state[f] = 3
            masukan[f] = st.slider(LABEL_FITUR.get(f, f), 0, 5, key=f)

st.divider()
hasil, skor = prediksi(bundle, masukan)
puas = hasil == "satisfied"
with st.container(border=True):
    st.subheader("Hasil Prediksi")
    if puas:
        st.success("### PUAS (satisfied)\nPenumpang ini diprediksi **puas** dengan penerbangannya.",
                   icon=":material/sentiment_satisfied:")
    else:
        st.error("### NETRAL / TIDAK PUAS\nPenumpang ini diprediksi **netral atau tidak puas**.",
                 icon=":material/sentiment_dissatisfied:")
    if skor is not None:
        st.caption(f"Skor keputusan SVM: {skor:+.2f} — positif cenderung *puas*, negatif cenderung "
                   "*tidak puas*; makin jauh dari 0 makin yakin.")
```

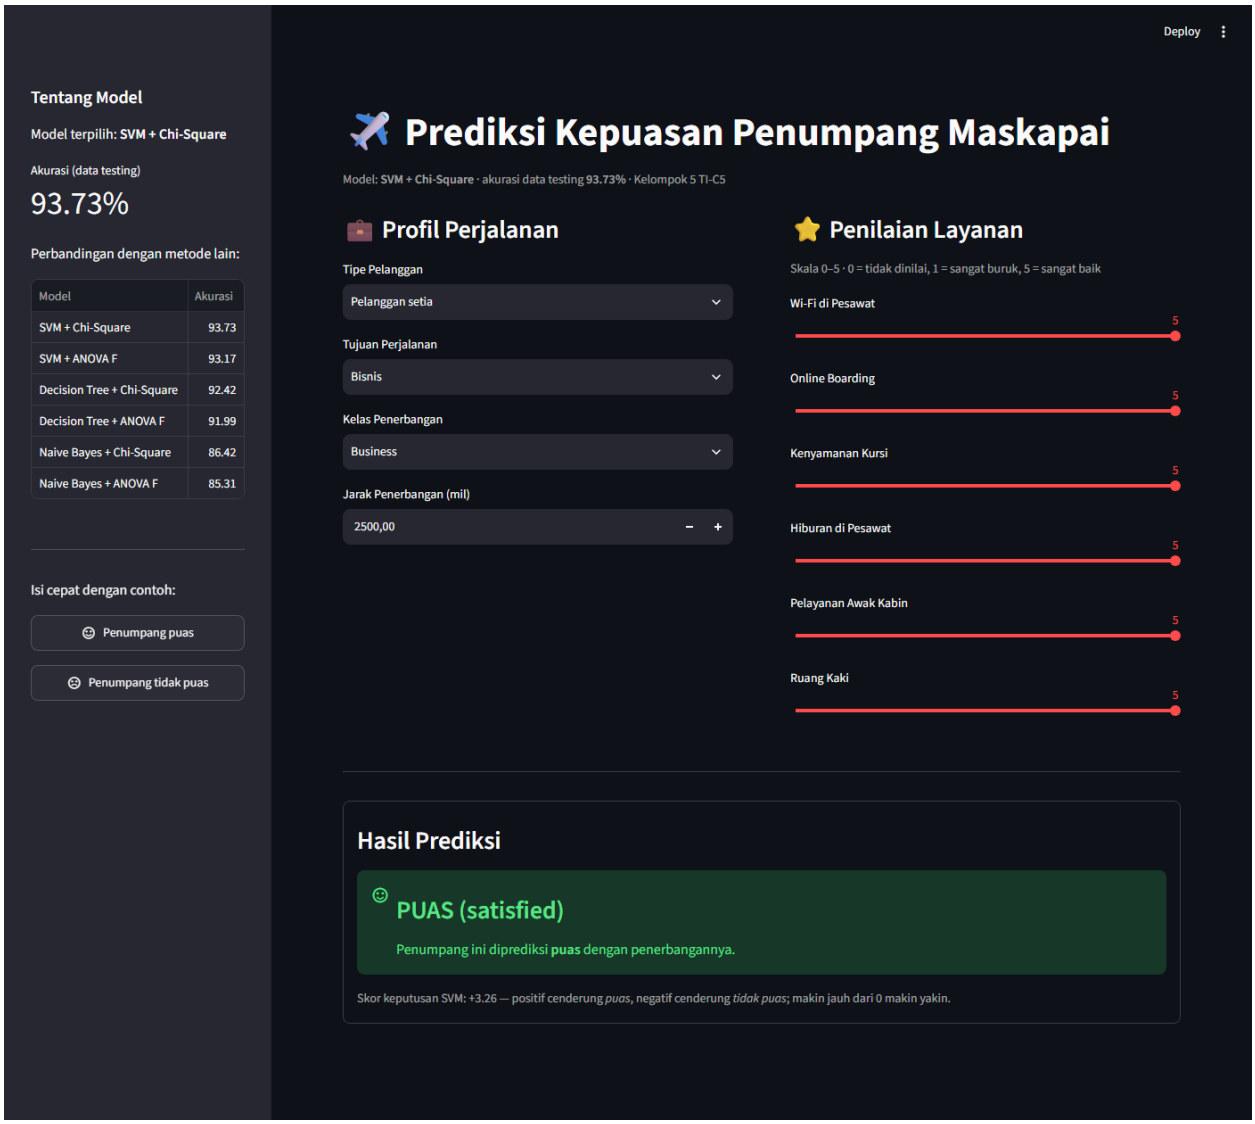
Kode 9. app_streamlit: form input dan hasil prediksi

Cara menjalankan aplikasi:

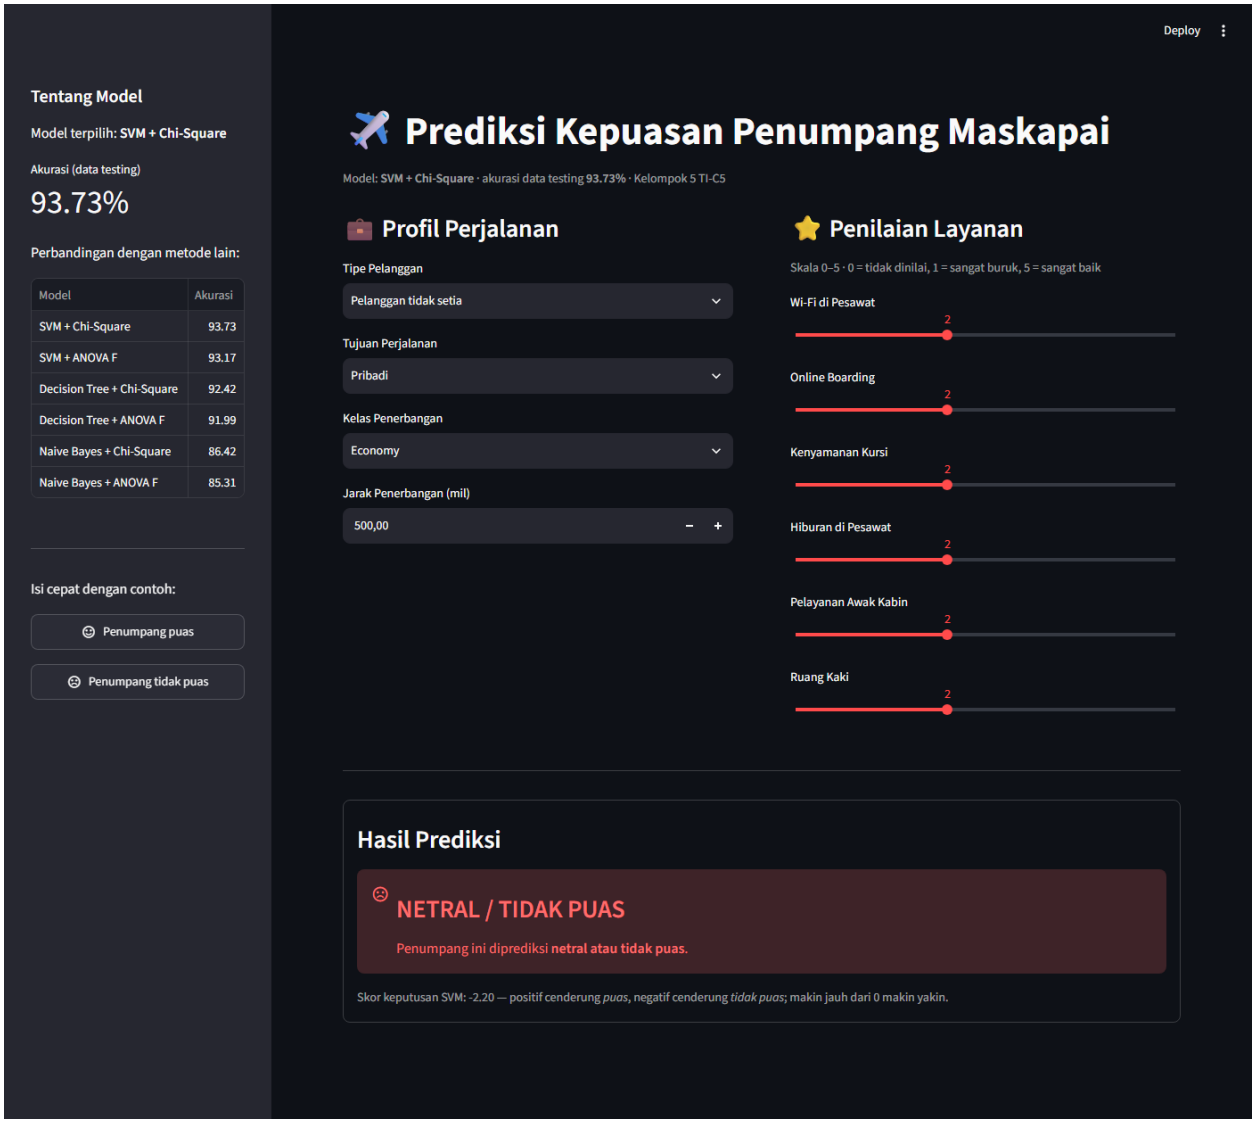
```
pip install streamlit scikit-learn pandas joblib
python klasifikasi_434241079.py          # melatih & menyimpan model
streamlit run app_streamlit_434241079.py # membuka UI di browser
```

Tampilan Aplikasi

Tampilan UI terdiri dari: **(1)** judul dan info model beserta akurasinya, **(2)** sidebar berisi perbandingan akurasi ketiga metode dan tombol *isi cepat* contoh penumpang, **(3)** kolom *Profil Perjalanan* (tipe pelanggan, tujuan perjalanan, kelas, jarak), **(4)** kolom *Penilaian Layanan* berupa slider 0–5, dan **(5)** kartu *Hasil Prediksi* berwarna hijau untuk *puas* atau merah untuk *netral/tidak puas*, lengkap dengan skor keputusan SVM.



UI: contoh penumpang yang diprediksi PUAS



UI: contoh penumpang yang diprediksi NETRAL / TIDAK PUAS

8. Kesimpulan

Ketiga metode berhasil diterapkan dengan tahapan yang sama seperti UTS. **SVM (kernel RBF)** memberikan kinerja terbaik dengan akurasi **93,73%** (seleksi Chi-Square), disusul **Decision Tree** (92,42%) dan **Naive Bayes** (86,42%). Naive Bayes tertinggal karena asumsi independensi fiturnya tidak terpenuhi, sedangkan SVM unggul berkat kemampuannya memodelkan pola non-linear meski waktu pelatihannya paling lama. Model SVM terbaik kemudian diwujudkan dalam aplikasi Streamlit yang dapat memprediksi kepuasan penumpang secara interaktif.