LAPORAN TUGAS

CLUSTERING K-MEANS

Dataset Mall Customers – Mata Kuliah Machine Learning Pertemuan 9

Kelas : TI-C5 | Kelompok : 5

Anggota Kelompok:

1. Muhammad Irfan Nuha (434241079)
2. Bunga Lala Sal Sabila (434241066)

Tugas Kelompok

---

1. Pendahuluan

Clustering adalah teknik *unsupervised learning* untuk mengelompokkan data berdasarkan kemiripan fiturnya, tanpa label kelas. Pada bagian ini kami melengkapi kode modul yang masih berisi titik-titik, yaitu clustering **K-Means** pada dataset *Mall Customers* (200 pelanggan dengan kolom Gender, Age, Annual Income, dan Spending Score). Tujuannya mengelompokkan pelanggan berdasarkan **pendapatan tahunan** dan **skor belanja**.

K-Means bekerja secara iteratif: menentukan centroid awal, memasukkan setiap data ke centroid terdekat, memperbarui posisi centroid, lalu mengulanginya sampai konvergen.

2. Import Library dan Data

py kmeans_mall_customers.py

```
14  # 1
15  # import tools
16  import numpy as np
17  import pandas as pd
18  import matplotlib.pyplot as plt
19  import seaborn as sns
20  from sklearn.cluster import KMeans
21  from sklearn.metrics import silhouette_score
22
23  BASE_DIR = os.path.dirname(os.path.abspath(__file__))
24  OUT_DIR = os.path.join(BASE_DIR, "output")
25  os.makedirs(OUT_DIR, exist_ok=True)
26
27
28  def tampilkan(nama_file):
29      """Simpan figure ke folder output lalu tampilkan (plt.show)."""
30      plt.savefig(os.path.join(OUT_DIR, nama_file), dpi=110, bbox_inches="tight")
31      plt.show()
32      plt.close()
33
34
35  def judul(teks):
36      print("\n" + "=" * 62)
37      print(f"  {teks}")
38      print("=" * 62)
```

Kode 1. Import library dan fungsi bantu

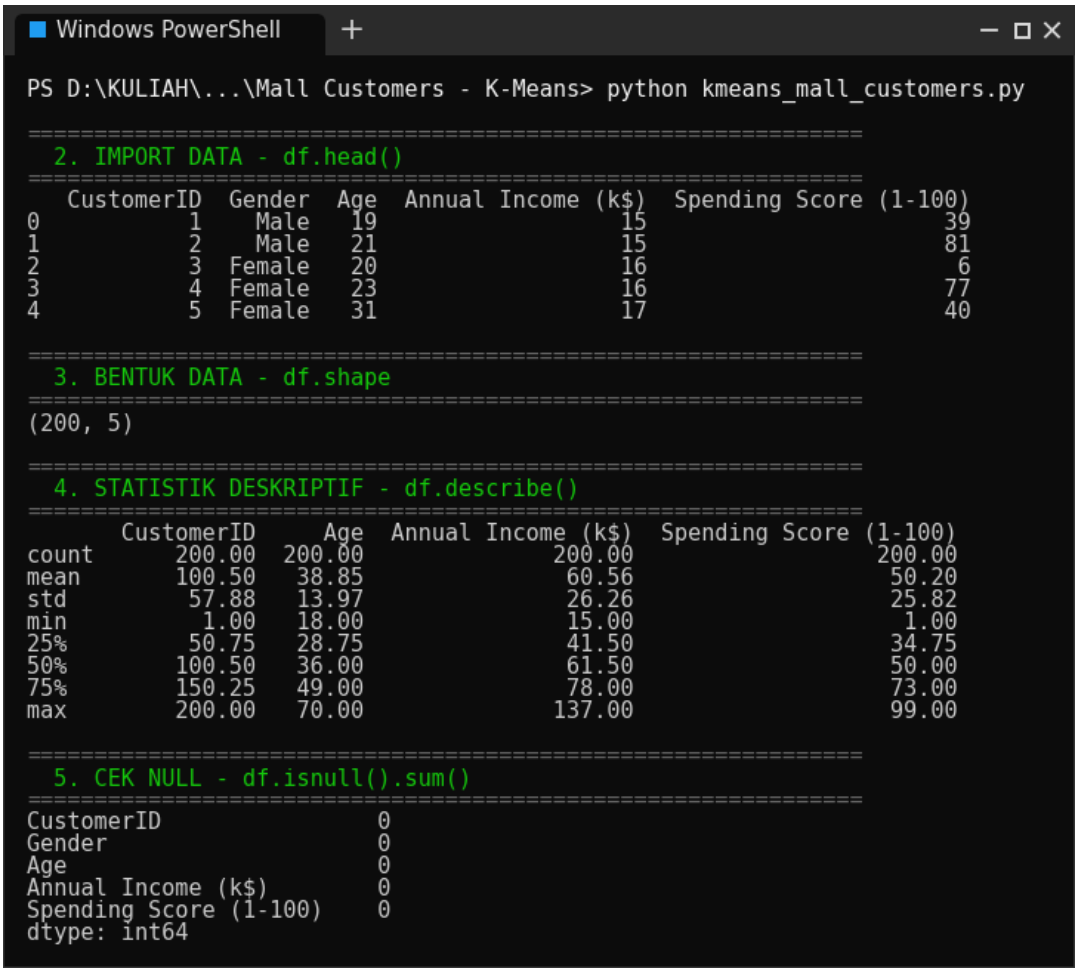
py kmeans_mall_customers.py

```
41  # 2
42  # import data
43  df = pd.read_csv(os.path.join(BASE_DIR, "Mall_Customers.csv"))
44  judul("2. IMPORT DATA - df.head()")
45  print(df.head())
46
47  # 3
48  # amati bentuk data
49  judul("3. BENTUK DATA - df.shape")
50  print(df.shape)
51
52  # 4
53  # Melihat ringkasan statistik deskriptif dari DataFrame
54  judul("4. STATISTIK DESKRIPTIF - df.describe()")
55  print(df.describe().round(2))
56
57  # 5
58  # cek null data
59  judul("5. CEK NULL - df.isnull().sum()")
60  print(df.isnull().sum())
```

Kode 2. Import data, bentuk data, statistik deskriptif, cek null

Langkah 2 sampai 5 melengkapi titik-titik pada modul: **df.describe()** untuk ringkasan statistik dan **df.isnull().sum()** untuk mengecek data kosong. Data berisi 200 baris dan 5 kolom, tanpa satu

pun nilai kosong. Usia pelanggan 18 sampai 70 tahun, pendapatan 15 sampai 137 ribu dolar, dan skor belanja 1 sampai 99.

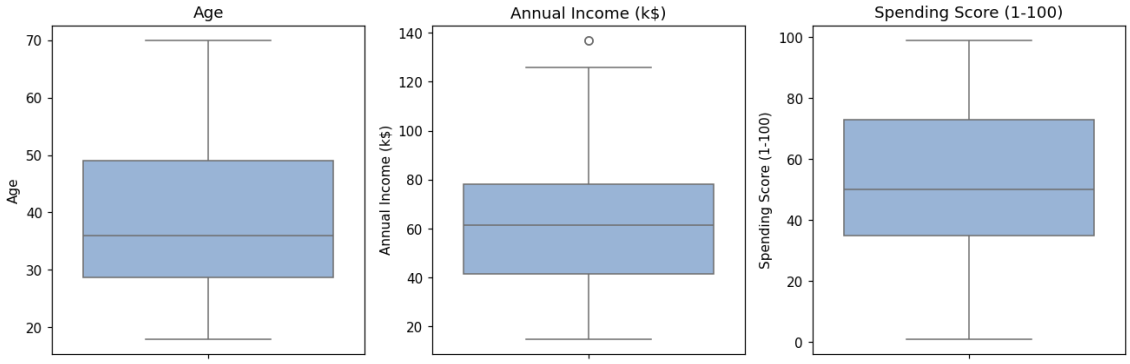


Output langkah 2 sampai 5

3. Cek Outlier

```python
# 6
# cek outlier
judul("6. CEK OUTLIER (metode IQR)")
kolom_numerik = ["Age", "Annual Income (k$)", "Spending Score (1-100)"]
for kol in kolom_numerik:
    q1, q3 = df[kol].quantile(0.25), df[kol].quantile(0.75)
    iqr = q3 - q1
    bawah, atas = q1 - 1.5 * iqr, q3 + 1.5 * iqr
    jumlah = ((df[kol] < bawah) | (df[kol] > atas)).sum()
    print(f"   {kol:<24} batas [{bawah:7.2f}, {atas:7.2f}]  outlier = {jumlah}")
plt.figure(figsize=(12, 4))
for i, kol in enumerate(kolom_numerik, 1):
    plt.subplot(1, 3, i)
    sns.boxplot(y=df[kol], color="#8fb3e0")
    plt.title(kol)
plt.tight_layout()
tampilkan("mall_6_boxplot_outlier.png")
```

Kode 3. Cek outlier dengan IQR dan boxplot



Boxplot tiap fitur numerik

Langkah 6 mengecek outlier dengan metode **IQR**. Hanya kolom *Annual Income* yang memiliki 2 outlier (pendapatan di atas 132,75 ribu dolar). Data tersebut **tidak dibuang**, karena nilainya wajar (pelanggan berpenghasilan tinggi) dan jumlahnya sangat sedikit, sehingga tetap dipakai dalam clustering.

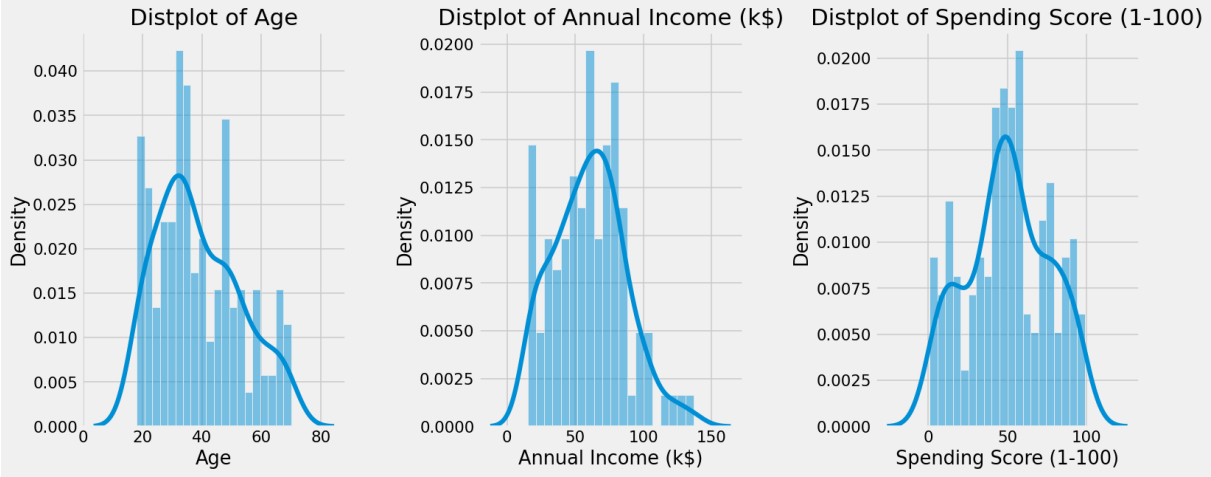
4. Visualisasi Data

py kmeans_mall_customers.py

```
80  # 7
81  # amati bentuk visual masing-masing fitur
82  plt.style.use('fivethirtyeight')
83  plt.figure(1, figsize=(15, 6))
84  n = 0
85  for x in ['Age', 'Annual Income (k$)', 'Spending Score (1-100)']:
86      n += 1
87      plt.subplot(1, 3, n)
88      plt.subplots_adjust(hspace=0.5, wspace=0.5)
89      sns.histplot(
90          df[x], kde=True,
91          stat="density", kde_kws=dict(cut=3), bins=20)
92      plt.title('Distplot of {}'.format(x))
93  tampilkan("mall_7_distribusi.png")
94
95  # 8
96  # Ploting untuk mencari relasi antara Age , Annual Income and Spending Score
97  plt.figure(1, figsize=(15, 20))
98  n = 0
99  for x in ['Age', 'Annual Income (k$)', 'Spending Score (1-100)']:
100     for y in ['Age', 'Annual Income (k$)', 'Spending Score (1-100)']:
101         n += 1
102         plt.subplot(3, 3, n)
103         plt.subplots_adjust(hspace=0.5, wspace=0.5)
104         sns.regplot(x=x, y=y, data=df)
105         plt.ylabel(y.split()[0] + ' ' + y.split()[1] if len(y.split()) > 1 else y)
106 tampilkan("mall_8_relasi.png")
107
108 # 9
109 # Melihat sebaran Spending Score dan Annual Income pada Gender
110 plt.figure(1, figsize=(15, 8))
111 for gender in ['Male', 'Female']:
112     plt.scatter(x='Annual Income (k$)', y='Spending Score (1-100)',
113                 data=df[df['Gender'] == gender], s=200, alpha=0.5,
114                 label=gender)
115     plt.xlabel('Annual Income (k$)'), plt.ylabel('Spending Score (1-100)')
116     plt.title('Annual Income vs Spending Score')
117     plt.legend()
118 tampilkan("mall_9_gender.png")
```

Kode 4. Visualisasi distribusi, relasi, dan sebaran per gender

Langkah 7 sampai 9 melengkapi perintah untuk **menampilkan figure** (*plt.show()*). Histogram memperlihatkan sebaran tiap fitur, regplot memperlihatkan hubungan antar-fitur, dan scatter plot per gender memperlihatkan bahwa titik-titik data pada bidang *Annual Income* vs *Spending Score* sudah membentuk sekitar lima gerombol yang terlihat jelas.



Distribusi tiap fitur



Annual Income vs Spending Score per gender



Relasi antar-fitur (regplot)

5. Elbow Method dan K-Means

py kmeans_mall_customers.py

```python
# 10
# Merancang K-Means untuk spending score vs annual income
# Menentukan nilai k yang sesuai dengan Elbow-Method
X1 = df[['Annual Income (k$)', 'Spending Score (1-100)']].iloc[:, :].values
inertia = []
for n in range(1, 11):
    algorithm = (KMeans(n_clusters=n, init='k-means++', n_init=10, max_iter=300, random_state=111))
    algorithm.fit(X1)
    inertia.append(algorithm.inertia_)

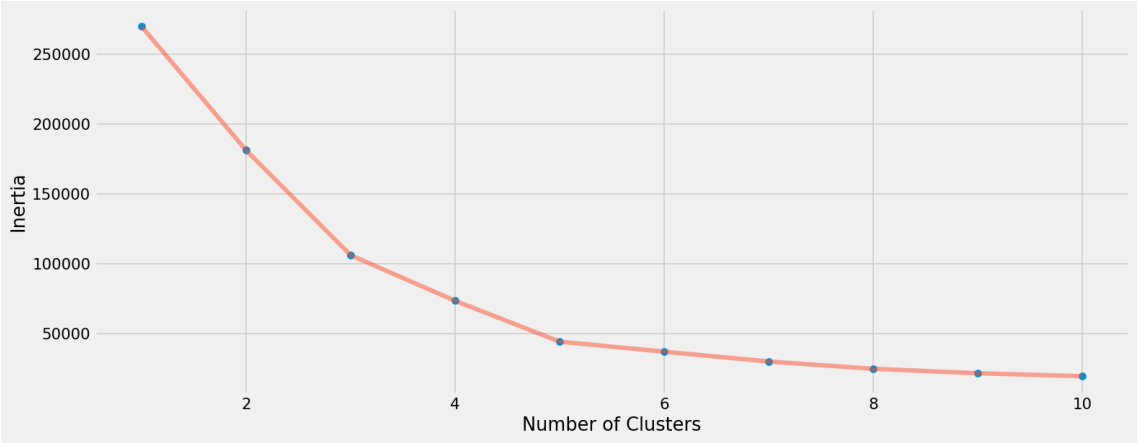
judul("10. ELBOW METHOD - nilai inertia")
for k, nilai in enumerate(inertia, 1):
    print(f"   k = {k:<2}  inertia = {nilai:12.2f}")

# Plot bentuk visual elbow
plt.figure(1, figsize=(15, 6))
plt.plot(range(1, 11), inertia, 'o')
plt.plot(range(1, 11), inertia, '-', alpha=0.5)
plt.xlabel('Number of Clusters'), plt.ylabel('Inertia')
tampilkan("mall_10_elbow.png")

# 11
# Membangun K-Means
algorithm = (KMeans(n_clusters=5, init='k-means++', n_init=10, max_iter=300,
                    tol=0.0001, random_state=111, algorithm='elkan'))
algorithm.fit(X1)
labels2 = algorithm.labels_
centroids2 = algorithm.cluster_centers_

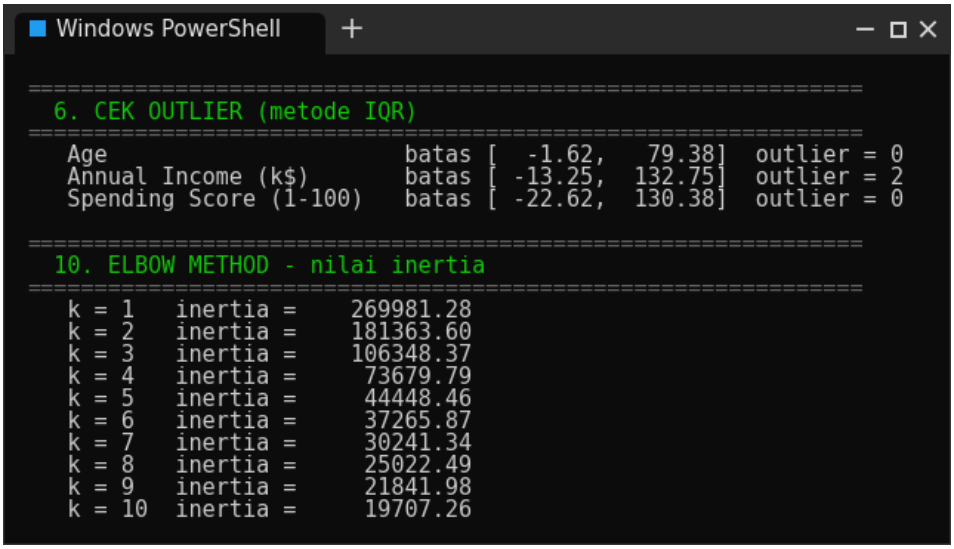
judul("11. K-MEANS (k = 5) - centroid tiap cluster")
print(pd.DataFrame(centroids2, columns=["Annual Income (k$)", "Spending Score (1-100)"]).round(2))
print("\nJumlah anggota tiap cluster:")
print(pd.Series(labels2).value_counts().sort_index().to_string())
```

Kode 5. Elbow Method dan pembangunan K-Means (k = 5)



Grafik Elbow Method

Langkah 10 menghitung **inertia** (jumlah kuadrat jarak data ke centroid) untuk k = 1 sampai 10. Inertia turun tajam sampai **k = 5** (dari 269,981 menjadi 44,448, turun 84%), lalu setelah itu penurunannya landai. Titik siku tersebut menjadi dasar pengisian titik-titik pada langkah 11, yaitu **n_clusters = 5**.



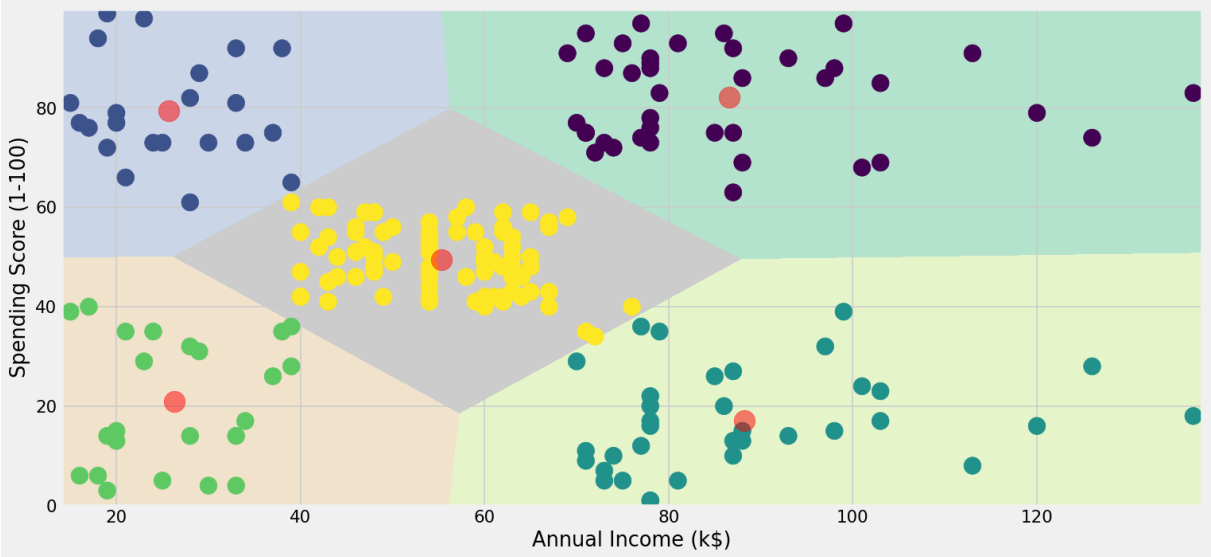
Output cek outlier dan nilai inertia

6. Hasil Clustering dan Silhouette Score

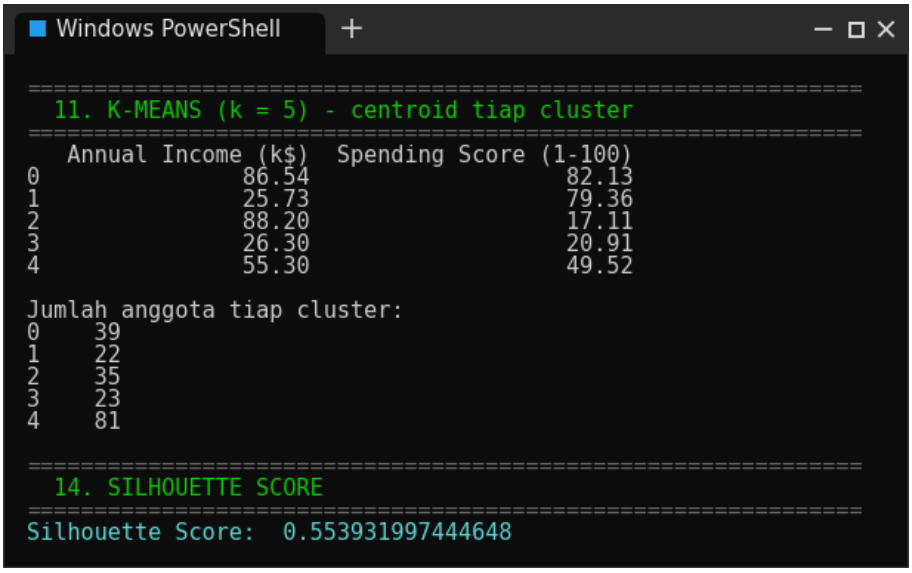
py kmeans_mall_customers.py

```
154 # 12
155 # Menyiapkan data untuk bentuk visual cluster
156 labels2 = algorithm.labels_
157 centroids2 = algorithm.cluster_centers_
158 step = 0.02
159 x_min, x_max = X1[:, 0].min() - 1, X1[:, 0].max() + 1
160 y_min, y_max = X1[:, 1].min() - 1, X1[:, 1].max() + 1
161 xx, yy = np.meshgrid(np.arange(x_min, x_max, step), np.arange(y_min, y_max, step))
162 Z1 = algorithm.predict(np.c_[xx.ravel(), yy.ravel()])  # array diratakan 1D
163
164 # 13
165 # Melihat bentuk visual cluster
166 plt.figure(1, figsize=(15, 7))
167 plt.clf()
168 Z1 = Z1.reshape(xx.shape)
169 plt.imshow(Z1, interpolation='nearest',
170            extent=(xx.min(), xx.max(), yy.min(), yy.max()),
171            cmap=plt.cm.Pastel2, aspect='auto', origin='lower')
172 plt.scatter(x='Annual Income (k$)', y='Spending Score (1-100)', data=df, c=labels2, s=200)
173 plt.scatter(x=centroids2[:, 0], y=centroids2[:, 1], s=300, c='red', alpha=0.5)
174 plt.ylabel('Spending Score (1-100)'), plt.xlabel('Annual Income (k$)')
175 tampilkan("mall_13_cluster.png")
176
177 # 14
178 # Melihat nilai Silhouette Score
179 judul("14. SILHOUETTE SCORE")
180 score2 = silhouette_score(X1, labels2)
181 print("Silhouette Score: ", score2)
```

Kode 6. Visualisasi cluster dan Silhouette Score



Hasil K-Means: 5 cluster pelanggan (titik merah = centroid)



Output centroid, jumlah anggota cluster, dan Silhouette Score

Model K-Means dengan k = 5 membagi pelanggan menjadi lima segmen yang mudah ditafsirkan: pendapatan tinggi & belanja tinggi (target utama promosi), pendapatan tinggi & belanja rendah, pendapatan rendah & belanja tinggi, pendapatan rendah & belanja rendah, serta segmen menengah yang paling besar (81 pelanggan). Batas antar-cluster digambar dengan *meshgrid* (langkah 12-13).

Kualitas cluster diukur dengan **Silhouette Score** sebesar **0.5539**. Nilai ini berada di rentang -1 sampai 1; di atas 0,5 menandakan cluster terpisah dengan baik dan anggotanya rapat.

7. Kesimpulan

Seluruh titik-titik pada modul berhasil dilengkapi dan program berjalan tanpa error. Elbow Method menunjukkan jumlah cluster terbaik adalah 5, dan K-Means menghasilkan lima segmen pelanggan dengan Silhouette Score 0.5539 yang tergolong baik.