LAPORAN TUGAS
CLUSTERING K-MODES

Dataset Student Performance Factors – Mata Kuliah Machine Learning Pertemuan 9

Kelas : TI-C5 | Kelompok : 5

Anggota Kelompok:

1. Muhammad Irfan Nuha (434241079)
2. Bunga Lala Sal Sabila (434241066)

Tugas Kelompok

---

1. Pendahuluan

Pada tugas kelompok ini kami melakukan clustering pada dataset **Student Performance Factors** (6.607 siswa, 20 kolom) memakai algoritma **K-Modes**, sesuai pembagian untuk kelompok ganjil. Dataset berisi faktor-faktor yang memengaruhi prestasi siswa: jam belajar, kehadiran, keterlibatan orang tua, motivasi, pendapatan keluarga, kualitas guru, dan lain-lain, serta nilai ujian akhir (*Exam_Score*).

K-Modes adalah pengembangan K-Means untuk data **kategorikal**. Bedanya, K-Means memakai rata-rata dan jarak Euclidean, sedangkan K-Modes memakai **modus** (nilai yang paling sering muncul) sebagai pusat cluster dan **jarak ketidakcocokan** (*matching dissimilarity*), yaitu banyaknya atribut yang nilainya berbeda. Karena sebagian besar kolom dataset ini berupa kategori (Low/Medium/High, Yes/No), K-Modes cocok dipakai.

2. Import Library

py kmodes_student_performance.py

```
17  import os
18  import time
19  import warnings
20  warnings.filterwarnings("ignore")
21  import numpy as np
22  import pandas as pd
23  import matplotlib.pyplot as plt
24  import seaborn as sns
25  from kmodes.kmodes import KModes
26  from sklearn.metrics import silhouette_score
27
28  BASE_DIR = os.path.dirname(os.path.abspath(__file__))
29  OUT_DIR = os.path.join(BASE_DIR, "output")
30  os.makedirs(OUT_DIR, exist_ok=True)
31  NILAI = "Exam_Score"          # tidak ikut di-cluster, dipakai untuk membaca hasil
32  K_MAKS = 10
```

Kode 1. Import library dan konfigurasi

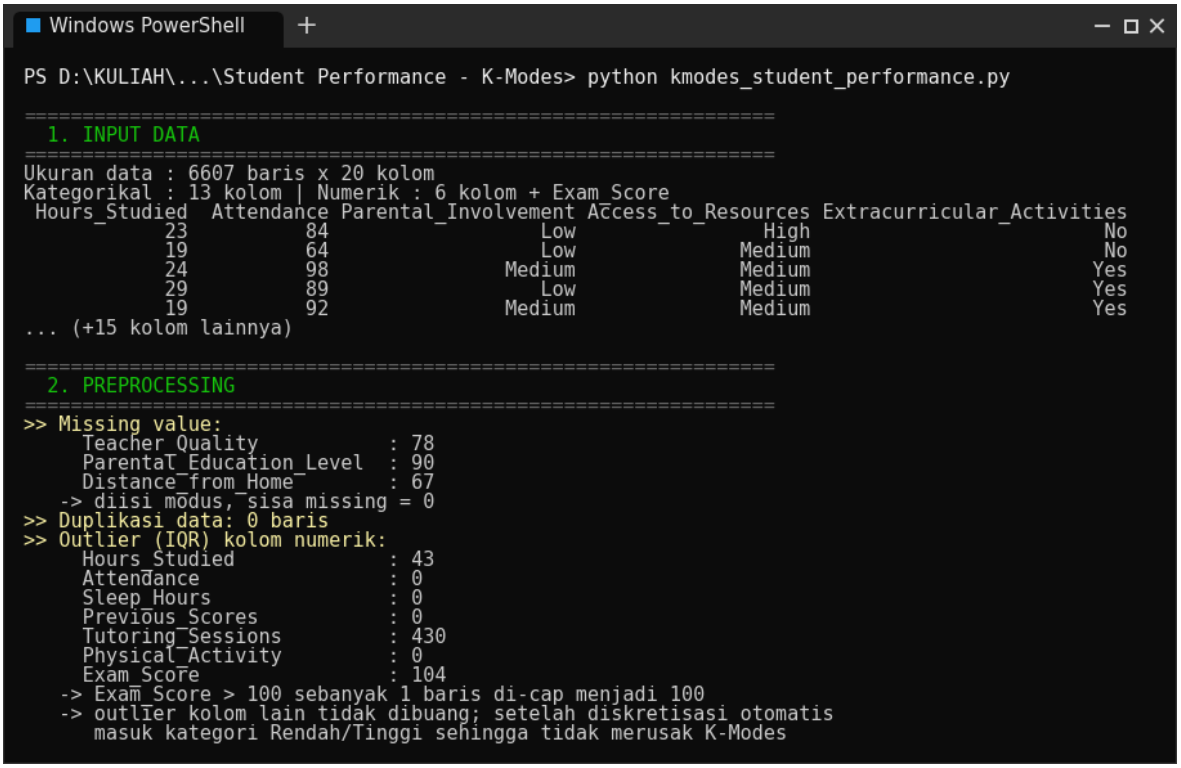
3. Input Data dan Preprocessing

py kmodes_student_performance.py

```
60      # ---------------- 1. INPUT ----------------
61      judul("1. INPUT DATA")
62      df = pd.read_csv(os.path.join(BASE_DIR, "StudentPerformanceFactors.csv"))
63      print(f"Ukuran data : {df.shape[0]} baris x {df.shape[1]} kolom")
64      kol_kat = df.select_dtypes(include="object").columns.tolist()
65      kol_num = [c for c in df.select_dtypes(include="number").columns if c != NILAI]
66      print(f"Kategorikal : {len(kol_kat)} kolom | Numerik : {len(kol_num)} kolom + {NILAI}")
67      print(df.iloc[:5, :5].to_string(index=False))
68      print(f"... (+{df.shape[1] - 5} kolom lainnya)")
69
70      # ---------------- 2. PREPROCESSING ----------------
71      judul("2. PREPROCESSING")
72      miss = df.isna().sum()
73      print(">> Missing value:")
74      for k, v in miss[miss > 0].items():
75          print(f"     {k:<26}: {v}")
76      for c in kol_kat:                                  # isi dengan modus
77          df[c] = df[c].fillna(df[c].mode()[0])
78      print(f"   -> diisi modus, sisa missing = {int(df.isna().sum().sum())}")
79
80      dup = int(df.duplicated().sum())
81      print(f">> Duplikasi data: {dup} baris")
82      df = df.drop_duplicates().reset_index(drop=True)
83
84      print(">> Outlier (IQR) kolom numerik:")
85      for c in kol_num + [NILAI]:
86          q1, q3 = df[c].quantile(0.25), df[c].quantile(0.75)
87          iqr = q3 - q1
88          n = int(((df[c] < q1 - 1.5 * iqr) | (df[c] > q3 + 1.5 * iqr)).sum())
89          print(f"     {c:<26}: {n}")
90      lebih = int((df[NILAI] > 100).sum())
91      df[NILAI] = df[NILAI].clip(upper=100)          # nilai ujian maksimal 100
92      print(f"   -> {NILAI} > 100 sebanyak {lebih} baris di-cap menjadi 100")
93      print("   -> outlier kolom lain tidak dibuang; setelah diskretisasi otomatis")
94      print("      masuk kategori Rendah/Tinggi sehingga tidak merusak K-Modes")
```

Kode 2. Input data dan preprocessing

Preprocessing menemukan **missing value** pada tiga kolom kategorikal (Teacher_Quality 78, Parental_Education_Level 90, Distance_from_Home 67) yang kami isi dengan **modus**, dan tidak ada **duplikasi**. Pengecekan **outlier** dengan IQR menemukan outlier di Hours_Studied, Tutoring_Sessions, dan Exam_Score. Satu nilai Exam_Score bernilai 101 kami batasi menjadi 100 karena nilai ujian maksimal 100. Outlier lain tidak dibuang, karena pada langkah berikutnya kolom numerik diubah menjadi kategori, sehingga nilai ekstrem cukup masuk ke kategori *Rendah* atau *Tinggi* tanpa mengganggu K-Modes.



Output input data dan preprocessing

4. Diskretisasi dan Elbow Method

py kmodes_student_performance.py

```
96      # ---------------- 3. DISKRETISASI ----------------
97      judul("3. DISKRETISASI NUMERIK -> KATEGORI (syarat K-Modes)")
98      data = df[kol_kat].copy()
99      for c in kol_num:
100         bins = pd.qcut(df[c], q=3, duplicates="drop", retbins=True)[1]
101         label = ["Rendah", "Sedang", "Tinggi"] if len(bins) == 4 else ["Rendah", "Tinggi"]
102         data[c] = pd.cut(df[c], bins=bins, labels=label, include_lowest=True).astype(str)
103         rentang = ", ".join(f"{l}<={b:g}" for l, b in zip(label, bins[1:]))
104         print(f"   {c:<20}: {rentang}")
105     print(f"   Fitur untuk clustering: {data.shape[1]} kolom kategorikal "
106           f"({NILAI} tidak ikut)")
107
108     # ---------------- 4. ELBOW METHOD ----------------
109     judul(f"4. ELBOW METHOD (k = 1 sampai {K_MAKS})")
110     cost = []
111     for k in range(1, K_MAKS + 1):
112         km = KModes(n_clusters=k, init="Huang", n_init=5, random_state=42)
113         km.fit(data)
114         cost.append(km.cost_)
115         print(f"   k = {k:<2}  cost = {km.cost_:10.0f}")
116     k_opt = titik_siku(cost)
117     print(f"   Titik siku (elbow) : k = {k_opt}")
118
119     plt.figure(figsize=(9, 4.5))
120     plt.plot(range(1, K_MAKS + 1), cost, "o-", color="#3d7cc9")
121     plt.axvline(k_opt, ls="--", color="crimson", label=f"k terpilih = {k_opt}")
122     plt.xlabel("Jumlah cluster (k)")
123     plt.ylabel("Cost (jumlah ketidakcocokan)")
124     plt.title("Elbow Method K-Modes - Student Performance")
125     plt.xticks(range(1, K_MAKS + 1))
126     plt.legend()
127     tampilkan("kmodes_1_elbow.png")
```

Kode 3. Diskretisasi kolom numerik dan Elbow Method

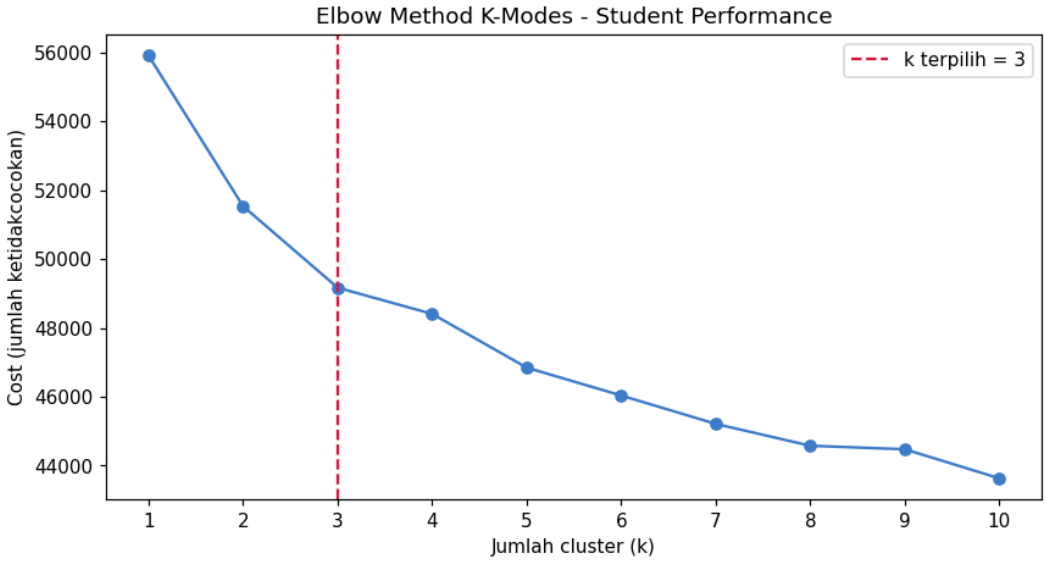
K-Modes hanya bisa memproses data kategorikal, jadi enam kolom numerik **didiskretisasi** menjadi kategori *Rendah / Sedang / Tinggi* berdasarkan kuantil (tiap kategori berisi kurang lebih sepertiga data). Physical_Activity hanya bisa dibagi dua (*Rendah / Tinggi*) karena nilainya sedikit dan banyak yang sama. Kolom **Exam_Score sengaja tidak ikut di-cluster**: clustering bersifat *unsupervised*, sehingga nilai ujian kami simpan untuk menilai apakah cluster yang terbentuk berkaitan dengan prestasi siswa.

py kmodes_student_performance.py

```
47  def titik_siku(nilai):
48      """Elbow otomatis: titik dengan jarak terjauh dari garis k=1 ke k=K_MAKS."""
49      y = np.array(nilai, dtype=float)
50      k = np.arange(1, len(y) + 1)
51      # normalisasi ke [0, 1] agar skala sumbu k dan cost sebanding
52      xn = (k - k[0]) / (k[-1] - k[0])
53      yn = (y - y.min()) / (y.max() - y.min())
54      # garis dari titik pertama (0, 1) ke terakhir (1, 0): x + y - 1 = 0
55      jarak = np.abs(xn + yn - 1) / np.sqrt(2)
56      return int(k[np.argmax(jarak)])
```

Kode 4. Fungsi penentuan titik siku otomatis

Jumlah cluster ditentukan dengan **Elbow Method**, memakai nilai *cost* K-Modes (total ketidakcocokan setiap siswa terhadap modus cluster-nya) untuk k = 1 sampai 10. Karena menentukan titik siku secara visual bisa subjektif, kami memakai fungsi *titik_siku()*: kedua sumbu dinormalisasi ke rentang 0 sampai 1, lalu dipilih k yang paling jauh dari garis lurus antara titik pertama dan terakhir. Hasilnya **k = 3**. Cost turun paling tajam dari k = 1 ke k = 3 (55,914 menjadi 49,171), setelah itu penurunannya melandai.



Grafik Elbow Method K-Modes

```
Windows PowerShell
+

============================================================
  3. DISKRETISASI NUMERIK -> KATEGORI (syarat K-Modes)
============================================================
   Hours_Studied       : Rendah<=17, Sedang<=23, Tinggi<=44
   Attendance          : Rendah<=73, Sedang<=87, Tinggi<=100
   Sleep_Hours         : Rendah<=6, Sedang<=8, Tinggi<=10
   Previous_Scores     : Rendah<=67, Sedang<=83, Tinggi<=100
   Tutoring_Sessions   : Rendah<=1, Sedang<=2, Tinggi<=8
   Physical_Activity   : Rendah<=3, Tinggi<=6
   Fitur untuk clustering: 19 kolom kategorikal (Exam_Score tidak ikut)

============================================================
  4. ELBOW METHOD (k = 1 sampai 10)
============================================================
   k = 1   cost =      55914
   k = 2   cost =      51538
   k = 3   cost =      49171
   k = 4   cost =      48409
   k = 5   cost =      46848
   k = 6   cost =      46038
   k = 7   cost =      45213
   k = 8   cost =      44578
   k = 9   cost =      44476
   k = 10  cost =      43631
   Titik siku (elbow) : k = 3
```

Output diskretisasi dan nilai cost

5. Clustering K-Modes dan Evaluasi

py kmodes_student_performance.py

```
129     # ---------------- 5. K-MODES ----------------
130     judul(f"5. K-MODES (k = {k_opt})")
131     mulai = time.time()
132     km = KModes(n_clusters=k_opt, init="Huang", n_init=10, random_state=42)
133     label_cluster = km.fit_predict(data)
134     print(f"   Iterasi selesai dalam {time.time() - mulai:.1f} detik, cost = {km.cost_:.0f}")
135     df["Cluster"] = label_cluster
136     ukuran = df["Cluster"].value_counts().sort_index()
137     for c, n in ukuran.items():
138         print(f"   Cluster {c}: {n} siswa ({n / len(df) * 100:.1f}%)")
139
140     centroid = pd.DataFrame(km.cluster_centroids_, columns=data.columns)
141     centroid.index = [f"Cluster {i}" for i in range(k_opt)]
142     centroid.T.to_csv(os.path.join(OUT_DIR, "centroid_kmodes.csv"))
143
144     # ---------------- 6. EVALUASI ----------------
145     judul("6. EVALUASI - SILHOUETTE SCORE (jarak Hamming)")
146     kode = data.apply(lambda s: s.astype("category").cat.codes)
147     skor = silhouette_score(kode, label_cluster, metric="hamming")
148     print(f"   Silhouette Score: {skor:.4f}")
```

Kode 5. Pembangunan K-Modes dan Silhouette Score

Windows PowerShell

```
======================================================================
  5. K-MODES (k = 3)
======================================================================
   Iterasi selesai dalam 10.5 detik, cost = 49171
   Cluster 0: 2768 siswa (41.9%)
   Cluster 1: 2143 siswa (32.4%)
   Cluster 2: 1696 siswa (25.7%)

======================================================================
  6. EVALUASI - SILHOUETTE SCORE (jarak Hamming)
======================================================================
   Silhouette Score: 0.0431
```

Output ukuran cluster dan Silhouette Score

Kualitas cluster diukur dengan **Silhouette Score** memakai **jarak Hamming** (proporsi atribut yang berbeda), padanan jarak ketidakcocokan K-Modes. Nilainya **0,0431**, positif tetapi kecil. Artinya sebagian besar siswa memang lebih mirip dengan cluster-nya sendiri, namun batas antar-cluster tidak tegas. Hal ini wajar untuk data kategorikal dengan banyak fitur: setiap siswa hanya berbeda di sebagian kecil atribut, dan 10 dari 19 fitur bahkan punya modus yang sama di semua cluster, sehingga jarak antar-cluster kecil. Silhouette Score K-Modes ini juga tidak bisa dibandingkan langsung dengan K-Means pada data numerik.

6. Profil Tiap Cluster

py kmodes_student_performance.py

```python
    # ---------------- 7. PROFIL CLUSTER ----------------
    judul(f"7. PROFIL CLUSTER (modus tiap fitur + rata-rata {NILAI})")
    beda = [c for c in centroid.columns if centroid[c].nunique() > 1]
    print("   Fitur yang membedakan antar-cluster:")
    print(centroid[beda].T.to_string())
    rata = df.groupby("Cluster")[NILAI].mean().round(2)
    print(f"\n   Rata-rata {NILAI} per cluster:")
    for c, v in rata.items():
        print(f"     Cluster {c}: {v}")

    df.to_csv(os.path.join(OUT_DIR, "hasil_clustering_kmodes.csv"), index=False)

    # grafik ukuran cluster + nilai ujian
    fig, ax = plt.subplots(1, 2, figsize=(13, 4.5))
    ax[0].bar([f"C{i}" for i in ukuran.index], ukuran.values, color="#3d7cc9")
    for i, v in enumerate(ukuran.values):
        ax[0].text(i, v, f"{v}", ha="center", va="bottom", fontsize=9)
    ax[0].set_title("Jumlah siswa per cluster")
    sns.boxplot(x=df["Cluster"].map(lambda c: f"C{c}"), y=df[NILAI], ax=ax[1],
                order=[f"C{i}" for i in range(k_opt)], color="#8fb3e0")
    ax[1].set_xlabel("Cluster")
    ax[1].set_title(f"Sebaran {NILAI} per cluster")
    plt.tight_layout()
    tampilkan("kmodes_2_ukuran_nilai.png")

    # komposisi fitur pembeda per cluster
    tampil = beda[:6]
    baris = (len(tampil) + 2) // 3
    fig, ax = plt.subplots(baris, 3, figsize=(15, 4 * baris))
    for a, f in zip(np.ravel(ax), tampil):
        pd.crosstab(df["Cluster"], data[f], normalize="index").mul(100).plot(
            kind="bar", stacked=True, ax=a, colormap="coolwarm", rot=0)
        a.set_title(f)
        a.set_ylabel("% siswa")
        a.legend(fontsize=7, loc="upper right")
    for a in np.ravel(ax)[len(tampil):]:
        a.axis("off")
    plt.tight_layout()
    tampilkan("kmodes_3_komposisi.png")

    print("\nHasil disimpan -> output/hasil_clustering_kmodes.csv, centroid_kmodes.csv")
```

Kode 6. Profil cluster dan visualisasi

Windows PowerShell

```
============================================================
  7. PROFIL CLUSTER (modus tiap fitur + rata-rata Exam_Score)
============================================================
   Fitur yang membedakan antar-cluster:
                              Cluster 0    Cluster 1 Cluster 2
Extracurricular_Activities           No          Yes       Yes
Motivation_Level                 Medium          Low    Medium
Family_Income                    Medium          Low       Low
Peer_Influence                  Neutral     Positive   Neutral
Parental_Education_Level    High School  High School   College
Gender                           Female         Male      Male
Hours_Studied                    Rendah       Tinggi    Sedang
Attendance                       Sedang       Rendah    Tinggi
Previous_Scores                  Tinggi       Tinggi    Sedang

   Rata-rata Exam_Score per cluster:
     Cluster 0: 66.81
     Cluster 1: 67.04
     Cluster 2: 68.17

Hasil disimpan -> output/hasil_clustering_kmodes.csv, centroid_kmodes.csv
```

Output profil cluster (modus fitur pembeda) dan rata-rata Exam_Score

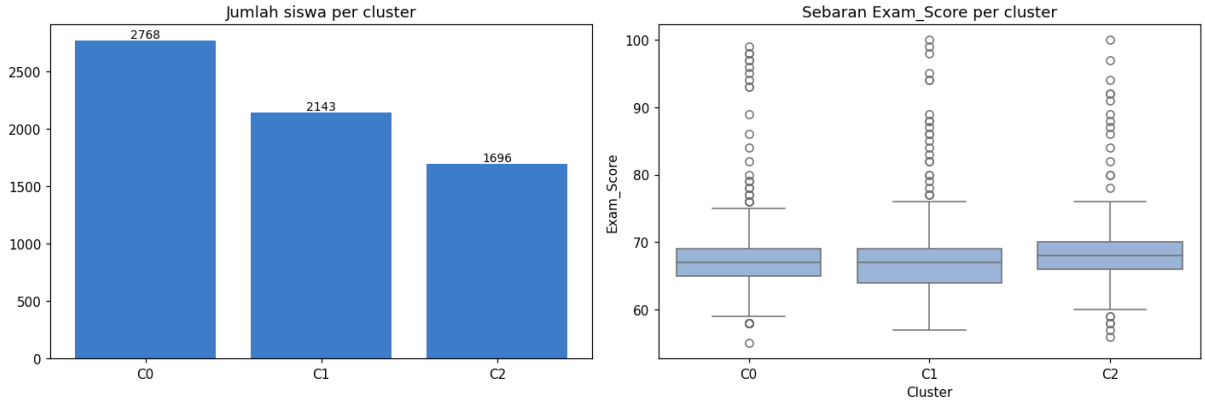
K-Modes dengan k = 3 membagi siswa menjadi **Cluster 0** (2,768 siswa, 41,9%), **Cluster 1** (2,143 siswa, 32,4%), **Cluster 2** (1,696 siswa, 25,7%). Fitur yang **sama** di semua cluster (10 fitur, misalnya Parental Involvement, Access to Resources, Internet Access) tidak membedakan

kelompok, sehingga karakter tiap cluster ditentukan oleh 9 fitur pembeda berikut:

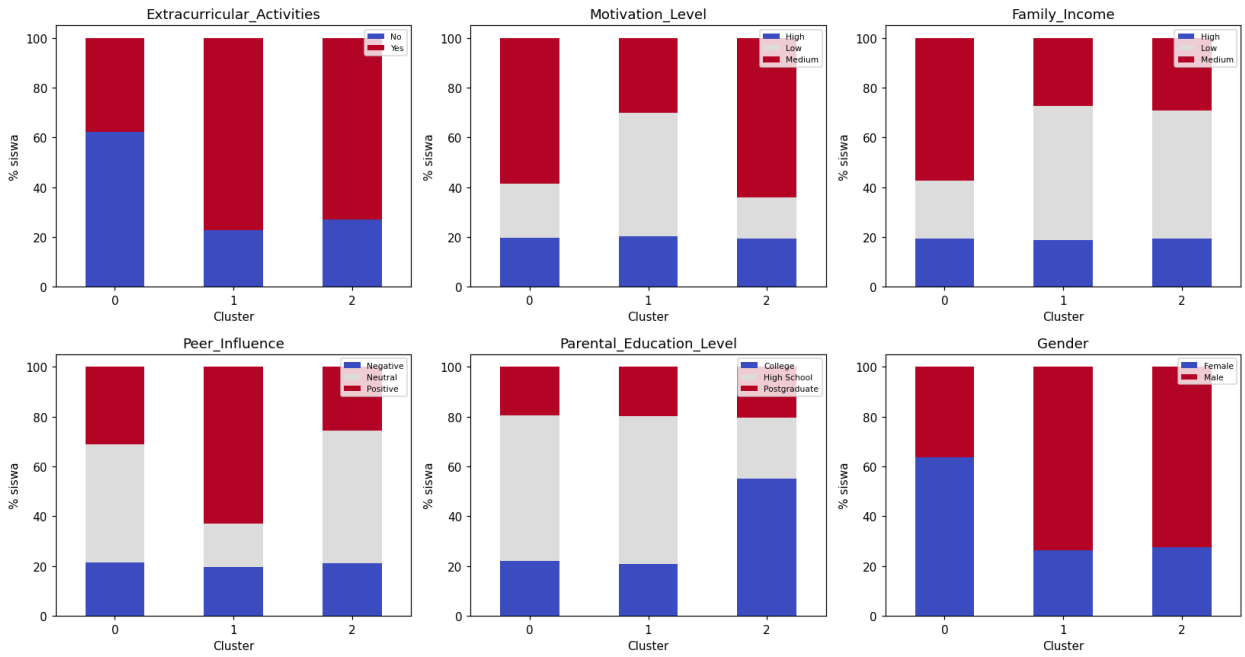
- **Cluster 0**: Extracurricular Activities = No, Motivation Level = Medium, Family Income = Medium, Peer Influence = Neutral, Parental Education Level = High School, Gender = Female, Hours Studied = Rendah, Attendance = Sedang, Previous Scores = Tinggi; rata-rata nilai ujian **66,81**.

- **Cluster 1**: Extracurricular Activities = Yes, Motivation Level = Low, Family Income = Low, Peer Influence = Positive, Parental Education Level = High School, Gender = Male, Hours Studied = Tinggi, Attendance = Rendah, Previous Scores = Tinggi; rata-rata nilai ujian **67,04**.

- **Cluster 2**: Extracurricular Activities = Yes, Motivation Level = Medium, Family Income = Low, Peer Influence = Neutral, Parental Education Level = College, Gender = Male, Hours Studied = Sedang, Attendance = Tinggi, Previous Scores = Sedang; rata-rata nilai ujian **68,17**.



Jumlah siswa dan sebaran Exam_Score per cluster



Komposisi fitur pembeda di tiap cluster (%)

Jika dihubungkan dengan nilai ujian, **Cluster 2** memiliki rata-rata Exam_Score tertinggi (68,17) dan **Cluster 0** terendah (66,81). Selisihnya hanya 1,36 poin, jadi cluster yang terbentuk lebih menggambarkan **profil latar belakang dan kebiasaan siswa** (keikutsertaan ekstrakurikuler, motivasi, pendapatan keluarga, jam belajar, kehadiran) daripada tingkat prestasi. Grafik komposisi memperlihatkan persentase kategori setiap fitur pembeda di tiap cluster.

7. Kesimpulan

K-Modes berhasil mengelompokkan 6.607 siswa ke dalam **3 cluster** setelah data dibersihkan dan kolom numerik didiskretisasi. Setiap cluster memiliki profil yang berbeda pada 9 fitur, namun Silhouette Score 0,0431 menunjukkan cluster saling tumpang tindih, dan perbedaan rata-rata nilai ujian antar-cluster kecil. Jadi pengelompokan ini lebih berguna untuk memahami tipe-tipe siswa berdasarkan latar belakang dan kebiasaannya, bukan untuk memisahkan siswa berprestasi tinggi dan rendah.