LAPORAN TUGAS
REGRESI LINEAR

Prediksi Keterlambatan Tiba Pesawat – Mata Kuliah Machine Learning Pertemuan 10

Kelas : TI-C5 | Kelompok : 5

Anggota Kelompok:

1. Muhammad Irfan Nuha (434241079)
2. Bunga Lala Sal Sabila (434241066)

Tugas Kelompok

---

1. Pendahuluan

Regresi adalah teknik *supervised learning* untuk memprediksi nilai berupa **angka** (kontinu). Berbeda dengan klasifikasi pada tugas sebelumnya yang menebak kategori (puas atau tidak puas), regresi menebak besaran, misalnya berapa menit sebuah penerbangan akan terlambat.

Pada tugas ini kami memakai **dataset UTS kelompok kami**, yaitu *Airline Passenger Satisfaction* (103.904 data penerbangan). Kolom target UTS (*satisfaction*) berupa kategori, sehingga untuk regresi kami memilih target angka **Arrival Delay in Minutes**: keterlambatan pesawat saat tiba. Kasus ini nyata dan berguna, karena maskapai perlu memperkirakan keterlambatan kedatangan untuk mengatur jadwal dan menginformasikan penumpang. Metode yang dipakai adalah **Linear Regression**.

2. Metode Linear Regression dan Metrik Evaluasi

Linear Regression memodelkan target sebagai jumlah berbobot dari fitur-fiturnya:

y = b0 + b1·x1 + b2·x2 + ... + bn·xn

dengan *b0* sebagai intercept dan *b1* sampai *bn* sebagai koefisien. Koefisien dicari dengan metode *Ordinary Least Squares*, yaitu meminimalkan jumlah kuadrat selisih antara nilai asli dan prediksi. Kelebihannya, setiap koefisien bisa dibaca langsung: berapa menit target berubah jika fitur naik satu satuan.

Model regresi dievaluasi dengan metrik berikut:

- **MAE** (*Mean Absolute Error*): rata-rata selisih absolut prediksi dengan nilai asli, dalam menit.
- **MSE** (*Mean Squared Error*): rata-rata kuadrat selisih; kesalahan besar dihukum lebih berat.
- **RMSE**: akar dari MSE, sehingga satuannya kembali ke menit.
- **R^2** (koefisien determinasi): proporsi variasi target yang berhasil dijelaskan model, dari 0 sampai 1; makin mendekati 1 makin baik.

3. Import Library, Input Data, dan Preprocessing

py regresi_kelompok5.py

```python
import os
import warnings
warnings.filterwarnings("ignore")
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

BASE_DIR = os.path.dirname(os.path.abspath(__file__))
OUT_DIR = os.path.join(BASE_DIR, "output")
os.makedirs(OUT_DIR, exist_ok=True)
TARGET = "Arrival Delay in Minutes"
```

Kode 1. Import library dan konfigurasi

py regresi_kelompok5.py

```python
    # ---------------- 1. INPUT ----------------
    judul("1. INPUT DATA")
    df = pd.read_csv(os.path.join(BASE_DIR, "train.csv"))
    df = df.drop(columns=[c for c in ["Unnamed: 0", "id"] if c in df.columns])
    print(f"Ukuran data : {df.shape[0]} baris x {df.shape[1]} kolom")
    print(f"Target      : {TARGET}")
    print(df[["Gender", "Class", "Flight Distance", "Departure Delay in Minutes", TARGET]]
          .head().to_string(index=False))

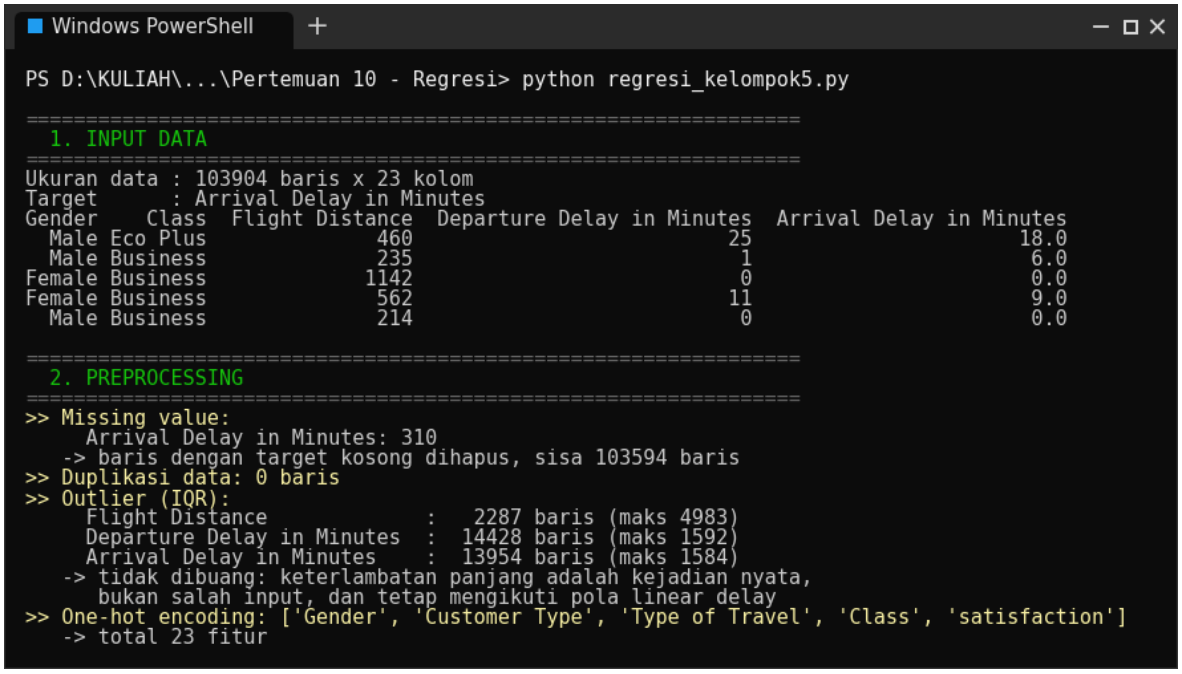
    # ---------------- 2. PREPROCESSING ----------------
    judul("2. PREPROCESSING")
    miss = df.isna().sum()
    print(">> Missing value:")
    for k, v in miss[miss > 0].items():
        print(f"     {k}: {v}")
    # missing ada di kolom TARGET -> baris dihapus (target tidak boleh dikarang/diisi)
    df = df.dropna(subset=[TARGET]).reset_index(drop=True)
    print(f"   -> baris dengan target kosong dihapus, sisa {len(df)} baris")

    dup = int(df.duplicated().sum())
    print(f">> Duplikasi data: {dup} baris")
    df = df.drop_duplicates().reset_index(drop=True)

    print(">> Outlier (IQR):")
    for c in ["Flight Distance", "Departure Delay in Minutes", TARGET]:
        q1, q3 = df[c].quantile(0.25), df[c].quantile(0.75)
        iqr = q3 - q1
        n = int(((df[c] < q1 - 1.5 * iqr) | (df[c] > q3 + 1.5 * iqr)).sum())
        print(f"     {c:<28}: {n:>6} baris (maks {df[c].max():.0f})")
    print("   -> tidak dibuang: keterlambatan panjang adalah kejadian nyata,")
    print("      bukan salah input, dan tetap mengikuti pola linear delay")

    # one-hot encoding untuk kolom kategorikal (Linear Regression butuh angka)
    kategori = df.select_dtypes(include="object").columns.tolist()
    df = pd.get_dummies(df, columns=kategori, drop_first=True, dtype=int)
    print(f">> One-hot encoding: {kategori}")
    print(f"   -> total {df.shape[1] - 1} fitur")
```

Kode 2. Input data dan preprocessing



Output input data dan preprocessing

Data awal berisi 103.904 baris dan 23 kolom (setelah kolom id dibuang). Missing value hanya ada di kolom target, yaitu 310 baris *Arrival Delay in Minutes*. Berbeda dengan UTS yang mengisinya dengan median, di sini baris tersebut **dihapus**: nilai target adalah "jawaban" yang dipelajari model, sehingga tidak boleh dikarang. Data tersisa **103,594** baris, tanpa duplikasi.

Pengecekan IQR menemukan banyak outlier pada kolom keterlambatan, karena 56% penerbangan tepat waktu (delay 0) sehingga keterlambatan sedikit saja sudah terhitung outlier. Outlier ini **tidak dibuang**: keterlambatan panjang adalah kejadian nyata, bukan salah input, dan tetap mengikuti pola linear. Lima kolom kategorikal di-*one-hot encoding* (*drop_first*) karena Linear Regression hanya menerima angka.

4. Korelasi, Split Data, dan Pelatihan Model

py regresi_kelompok5.py

```
83      # ---------------- 3. KORELASI ----------------
84      judul("3. KORELASI FITUR DENGAN TARGET (5 teratas)")
85      korelasi = df.corr()[TARGET].drop(TARGET).sort_values(key=abs, ascending=False)
86      for f, r in korelasi.head(5).items():
87          print(f"   {f:<34}: {r:+.3f}")
88
89      plt.figure(figsize=(8, 5))
90      plt.scatter(df["Departure Delay in Minutes"], df[TARGET], s=4, alpha=0.3, color="#3d7cc9")
91      plt.xlabel("Departure Delay in Minutes")
92      plt.ylabel(TARGET)
93      plt.title("Keterlambatan berangkat vs keterlambatan tiba")
94      tampilkan("reg_1_scatter_delay.png")
95
96      # ---------------- 4. SPLIT DATA ----------------
97      judul("4. SPLIT DATA 80% TRAINING / 20% TESTING")
98      X = df.drop(columns=[TARGET])
99      y = df[TARGET]
100     X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.20, random_state=42)
101     print(f"   Training : {len(X_train)} baris")
102     print(f"   Testing  : {len(X_test)} baris")
103
104     # ---------------- 5. LINEAR REGRESSION ----------------
105     judul("5. MODEL LINEAR REGRESSION")
106     model = LinearRegression()
107     model.fit(X_train, y_train)
108     print(f"   Intercept : {model.intercept_:.4f}")
109     koef = pd.Series(model.coef_, index=X.columns).sort_values(key=abs, ascending=False)
110     print("   Koefisien 5 fitur paling berpengaruh:")
111     for f, k in koef.head(5).items():
112         print(f"     {f:<34}: {k:+.4f}")
```

Kode 3. Korelasi, split 80/20, dan Linear Regression

Windows PowerShell

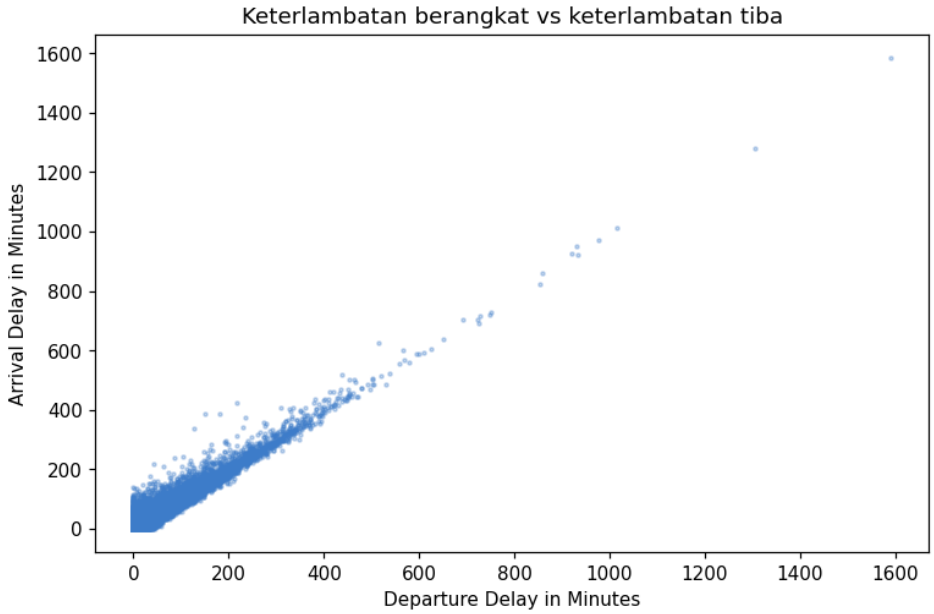
```
============================================================
  3. KORELASI FITUR DENGAN TARGET (5 teratas)
============================================================
   Departure Delay in Minutes        : +0.965
   Inflight service                  : -0.059
   satisfaction_satisfied            : -0.058
   On-board service                  : -0.035
   Food and drink                    : -0.033

============================================================
  4. SPLIT DATA 80% TRAINING / 20% TESTING
============================================================
   Training : 82875 baris
   Testing  : 20719 baris

============================================================
  5. MODEL LINEAR REGRESSION
============================================================
   Intercept : 2.1053
   Koefisien 5 fitur paling berpengaruh:
     Departure Delay in Minutes        : +0.9813
     satisfaction_satisfied            : -0.9455
     Type of Travel_Personal Travel    : -0.7367
     Customer Type_disloyal Customer   : -0.5092
     Class_Eco Plus                    : +0.2539
```

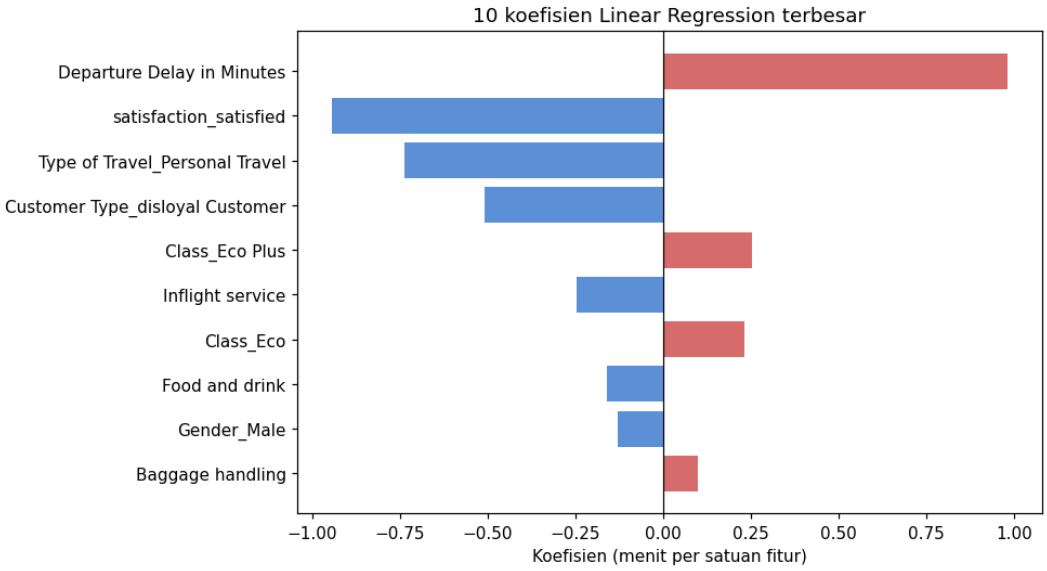
Output korelasi, split data, dan koefisien model

Korelasi menunjukkan satu fitur yang sangat dominan: **Departure Delay in Minutes** dengan korelasi **+0,965** terhadap target. Logikanya jelas: pesawat yang berangkat terlambat hampir pasti tiba terlambat. Fitur lain korelasinya sangat kecil (di bawah 0,06). Scatter plot memperlihatkan titik-titik membentuk garis lurus, yang menandakan hubungan linear sehingga Linear Regression cocok.



Departure Delay vs Arrival Delay

Data dibagi **80% training** dan **20% testing**, lalu model *LinearRegression()* dilatih. Koefisien terbesar adalah **Departure Delay = +0,9813**: setiap 1 menit keterlambatan berangkat menambah sekitar 0,98 menit keterlambatan tiba. Nilainya sedikit di bawah 1 karena pilot biasanya bisa mengejar sebagian keterlambatan di udara. Koefisien lain jauh lebih kecil; misalnya penumpang yang *satisfied* cenderung mengalami keterlambatan sekitar 1 menit lebih kecil. Intercept 2,11 berarti saat semua fitur bernilai 0, model menebak keterlambatan tiba sekitar 2 menit.



10 koefisien Linear Regression terbesar

5. Evaluasi Model

py regresi_kelompok5.py

```python
    # ---------------- 6. EVALUASI ----------------
    judul("6. EVALUASI MODEL")
    pred_train = model.predict(X_train)
    pred = model.predict(X_test)
    mae = mean_absolute_error(y_test, pred)
    mse = mean_squared_error(y_test, pred)
    rmse = np.sqrt(mse)
    r2 = r2_score(y_test, pred)
    print(f"   MAE  : {mae:.4f} menit")
    print(f"   MSE  : {mse:.4f}")
    print(f"   RMSE : {rmse:.4f} menit")
    print(f"   R2   : {r2:.4f}  (data training: {r2_score(y_train, pred_train):.4f})")
    pd.DataFrame({"Metrik": ["MAE", "MSE", "RMSE", "R2"], "Nilai": [mae, mse, rmse, r2]}).to_csv(
        os.path.join(OUT_DIR, "evaluasi.csv"), index=False)

    fig, ax = plt.subplots(1, 2, figsize=(13, 5))
    ax[0].scatter(y_test, pred, s=5, alpha=0.3, color="#3d7cc9")
    batas = [0, max(y_test.max(), pred.max())]
    ax[0].plot(batas, batas, "r--", label="prediksi = aktual")
    ax[0].set_xlabel("Arrival Delay aktual (menit)")
    ax[0].set_ylabel("Arrival Delay prediksi (menit)")
    ax[0].set_title(f"Aktual vs Prediksi (R2 = {r2:.3f})")
    ax[0].legend()
    residu = y_test - pred
    ax[1].hist(residu, bins=80, range=(-80, 80), color="#8fb3e0", edgecolor="white")
    ax[1].axvline(0, color="red", ls="--")
    ax[1].set_xlabel("Residu = aktual - prediksi (menit)")
    ax[1].set_ylabel("Jumlah data")
    ax[1].set_title("Sebaran residu")
    plt.tight_layout()
    tampilkan("reg_2_aktual_vs_prediksi.png")

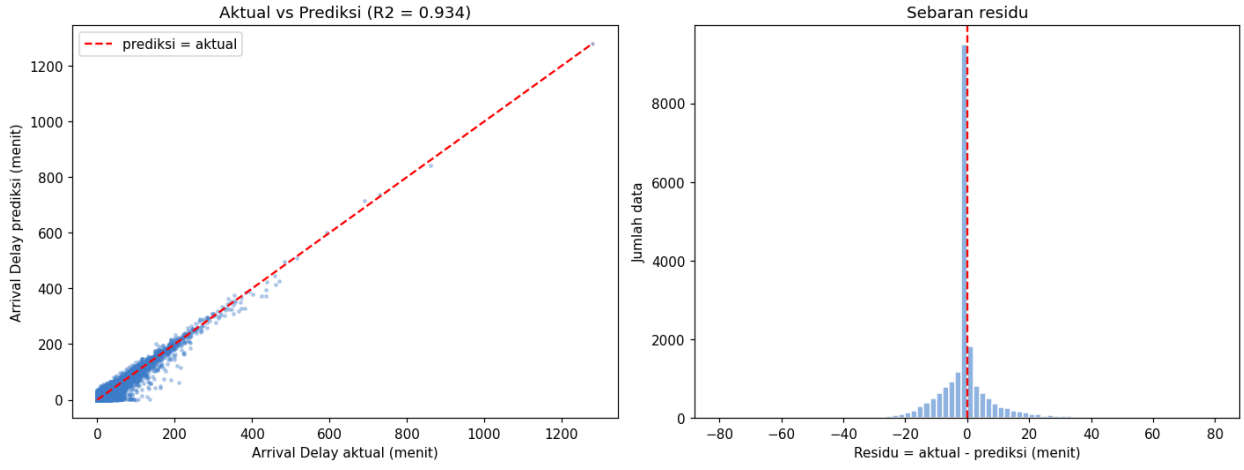
    plt.figure(figsize=(9, 5))
    top = koef.head(10).iloc[::-1]
    plt.barh(top.index, top.values, color=["#d66b6b" if v > 0 else "#5b8fd6" for v in top.values])
    plt.axvline(0, color="black", lw=0.8)
    plt.xlabel("Koefisien (menit per satuan fitur)")
    plt.title("10 koefisien Linear Regression terbesar")
    plt.tight_layout()
    tampilkan("reg_3_koefisien.png")
```

Kode 4. Evaluasi MAE, MSE, RMSE, R^2 dan grafik

Windows PowerShell

```
============================================================
  6. EVALUASI MODEL
============================================================
   MAE  : 5.2740 menit
   MSE  : 98.4713
   RMSE : 9.9233 menit
   R2   : 0.9344  (data training: 0.9318)
```

Output evaluasi model



Aktual vs prediksi (kiri) dan sebaran residu (kanan)

Hasil evaluasi pada data testing:

- **R^2 = 0,9344**: model menjelaskan sekitar 93,4% variasi keterlambatan tiba.

- **MAE = 5,27 menit**: rata-rata tebakan meleset sekitar 5 menit.

- **RMSE = 9,92 menit**: lebih besar dari MAE karena ada sebagian kecil penerbangan yang meleset jauh (misalnya keterlambatan berkurang drastis di udara).

R^2 data training (0,9318) hampir sama dengan data testing, artinya model **tidak overfitting** dan bekerja sama baiknya pada data yang belum pernah dilihat. Pada grafik aktual vs prediksi, titik-titik menempel di garis merah, dan histogram residu menumpuk di sekitar 0.

6. Contoh Prediksi

py regresi_kelompok5.py

```
155     # ---------------- 7. CONTOH PREDIKSI ----------------
156     judul("7. CONTOH PREDIKSI (5 data testing)")
157     contoh = pd.DataFrame({
158         "Departure Delay": X_test["Departure Delay in Minutes"].values[:5],
159         "Arrival Delay asli": y_test.values[:5],
160         "Prediksi": pred[:5].round(1),
161     })
162     contoh["Selisih"] = (contoh["Arrival Delay asli"] - contoh["Prediksi"]).round(1)
163     print(contoh.to_string(index=False))
164
165     hasil = X_test.assign(**{"Arrival Delay asli": y_test.values, "Prediksi": pred.round(2)})
166     hasil.to_csv(os.path.join(OUT_DIR, "hasil_prediksi.csv"), index=False)
167     print("\nHasil disimpan -> output/hasil_prediksi.csv, output/evaluasi.csv")
```

Kode 5. Contoh prediksi pada data testing

Windows PowerShell

```
============================================================
  7. CONTOH PREDIKSI (5 data testing)
============================================================
 Departure Delay  Arrival Delay asli  Prediksi  Selisih
               0                 0.0       0.9     -0.9
               0                 0.0       0.8     -0.8
               0                 0.0       1.0     -1.0
              94                79.0      93.6    -14.6
               0                 0.0       0.6     -0.6

Hasil disimpan -> output/hasil_prediksi.csv, output/evaluasi.csv
```

Output contoh prediksi

Tabel contoh prediksi memperlihatkan bahwa untuk penerbangan yang berangkat tepat waktu (Departure Delay 0), model menebak keterlambatan tiba sekitar 1 menit, sangat dekat dengan aslinya (0). Untuk penerbangan yang berangkat telat 94 menit, model menebak 93,6 menit sedangkan aslinya 79 menit; selisih ini terjadi karena pesawat tersebut berhasil mengejar keterlambatan di udara, sesuatu yang tidak tercatat di data.

7. Kesimpulan

Linear Regression berhasil memprediksi keterlambatan tiba pesawat dengan **R^2 0,9344**, **MAE 5,27 menit**, dan **RMSE 9,92 menit**, tanpa tanda overfitting. Faktor penentu utamanya adalah keterlambatan saat berangkat (koefisien 0,98), sedangkan fitur layanan dan profil penumpang hampir tidak berpengaruh. Karena hubungannya memang linear, metode sederhana seperti Linear Regression sudah cukup akurat sekaligus mudah dijelaskan.