

LAPORAN TUGAS

TRANSFORMASI DATA (NORMALISASI)

Mata Kuliah Machine Learning – Pertemuan 3

NAMA : Muhammad Irfan Nuha

NIM : 434241079

Kelas : TI-C5

Tugas Individu

1. Pendahuluan

Kolom-kolom di dalam satu dataset sering punya rentang nilai yang timpang. Pada data kartu kredit misalnya, CREDIT_LIMIT bisa mencapai belasan ribu sementara kolom frekuensi hanya bergerak di antara 0 dan 1. Kalau dibiarkan, kolom berangka besar akan mendominasi perhitungan pada banyak algoritma machine learning (terutama yang berbasis jarak seperti KNN atau K-Means) sehingga kolom kecil nyaris tidak diperhitungkan. Normalisasi menyamakan skala antar-kolom supaya setiap fitur punya bobot yang setara. Laporan ini menormalisasi tiga dataset dengan tiga metode yang berbeda dan membandingkan hasilnya.

2. Tiga Metode Normalisasi

Ada tiga metode yang dipakai, masing-masing dengan rumus dan karakter berbeda:

Simple Feature Scaling membagi tiap nilai dengan nilai maksimum kolomnya, $x' = x / \max(x)$. Hasilnya berkisar sampai 1, tapi nilai minimumnya belum tentu 0 kalau data aslinya tidak dimulai dari 0.

Min-Max Normalization memetakan seluruh rentang ke $[0, 1]$ dengan $x' = (x - \min) / (\max - \min)$. Nilai terkecil selalu jadi 0 dan terbesar jadi 1.

Z-Score Standardization memusatkan data ke rata-rata 0 dengan simpangan baku 1, $x' = (x - \text{mean}) / \text{std}$. Cocok saat data mendekati distribusi normal, dan tidak membatasi nilai ke rentang tertentu.

Sebagai verifikasi, ketiga rumus diterapkan pada contoh dari modul, $X = [7, 10, 15, 20, 25]$. Hasilnya persis sama dengan tabel di modul: Min-Max menghasilkan 0 sampai 1, dan Z-Score menghasilkan -1,286 sampai 1,472. Ini memastikan implementasi kodenya benar sebelum dipakai ke data asli.

X	Simple Feature Scaling	Min-Max	Z-Score
7	0.2800	0.0000	-1.2864
10	0.4000	0.1667	-0.8270
15	0.6000	0.4444	-0.0613
20	0.8000	0.7222	0.7044
25	1.0000	1.0000	1.4702

Tabel: verifikasi rumus pada contoh modul $X = [7, 10, 15, 20, 25]$

3. Alur Pengerjaan

Sesuai instruksi tugas, data dibersihkan lebih dulu sebelum dinormalisasi. Missing value diisi (median untuk kolom angka, modus untuk kategori) dan outlier dijinakkan dengan capping IQR, persis seperti pada tugas preprocessing sebelumnya. Urutan ini penting: kalau outlier belum ditangani, nilai maksimum dan minimum kolom akan tertarik oleh angka ekstrem, sehingga hasil Min-Max maupun Simple Feature Scaling menjadi tidak representatif. Normalisasi hanya diterapkan pada kolom numerik kontinu; kolom biner dan kategori dibiarkan.


4. Dataset: CC GENERAL.csv

Ukuran data **8950 baris x 18 kolom**. Preprocessing menangani **314 sel kosong** dan meng-cap outlier pada **16 kolom kontinu**, lalu kolom-kolom itu dinormalisasi.

Kolom	Asli (min ... max)	SFS (maks)	Min-Max (min ... max)	Z (mean / std)
BALANCE	0.00 ... 4942.93	1.00	0.00 ... 1.00	0.00 / 1.00
BALANCE_FREQUENCY	0.72 ... 1.00	1.00	0.00 ... 1.00	0.00 / 1.00
PURCHASES	0.00 ... 2715.87	1.00	0.00 ... 1.00	0.00 / 1.00
ONEOFF_PURCHASES	0.00 ... 1443.51	1.00	0.00 ... 1.00	0.00 / 1.00
INSTALLMENTS_PURCHASES	0.00 ... 1171.59	1.00	0.00 ... 1.00	0.00 / 1.00
CASH_ADVANCE	0.00 ... 2784.55	1.00	0.00 ... 1.00	0.00 / 1.00
PURCHASES_FREQUENCY	0.00 ... 1.00	1.00	0.00 ... 1.00	0.00 / 1.00
ONEOFF_PURCHASES_FREQUENCY	0.00 ... 0.75	1.00	0.00 ... 1.00	0.00 / 1.00
PURCHASES_INSTALLMENTS_FRE	0.00 ... 1.00	1.00	0.00 ... 1.00	0.00 / 1.00
CASH_ADVANCE_FREQUENCY	0.00 ... 0.56	1.00	0.00 ... 1.00	0.00 / 1.00
CASH_ADVANCE_TRX	0.00 ... 10.00	1.00	0.00 ... 1.00	0.00 / 1.00
PURCHASES_TRX	0.00 ... 41.00	1.00	0.00 ... 1.00	0.00 / 1.00
CREDIT_LIMIT	50.00 ... 13850.00	1.00	0.00 ... 1.00	0.00 / 1.00
PAYMENTS	0.00 ... 4177.92	1.00	0.00 ... 1.00	0.00 / 1.00
MINIMUM_PAYMENTS	0.02 ... 1715.50	1.00	0.00 ... 1.00	0.00 / 1.00
PRC_FULL_PAYMENT	0.00 ... 0.36	1.00	0.00 ... 1.00	0.00 / 1.00

Tabel: rentang tiap kolom sebelum dan sesudah normalisasi (bukti hasil tiap metode)

Pada 16 kolom kontinu, ketiga metode bekerja seperti yang diharapkan. Yang menarik adalah beda Simple Feature Scaling dan Min-Max pada kolom **BALANCE_FREQUENCY**: karena nilai aslinya tidak pernah di bawah 0,72, Simple Feature Scaling menyisakan minimum sekitar 0,72, sedangkan Min-Max menariknya tepat ke 0. Ini contoh nyata kenapa dua metode yang sekilas mirip bisa memberi hasil berbeda. Kolom Z-Score semuanya berpusat di mean 0 dengan std 1.



Grafik: distribusi satu kolom perwakilan, asli vs tiga metode normalisasi


5. Dataset: concrete_data.csv

Ukuran data **1030 baris x 9 kolom**. Preprocessing menangani **0 sel kosong** dan meng-cap outlier pada **8 kolom kontinu**, lalu kolom-kolom itu dinormalisasi.

Kolom	Asli (min ... max)	SFS (maks)	Min-Max (min ... max)	Z (mean / std)
cement	102.00 ... 540.00	1.00	0.00 ... 1.00	0.00 / 1.00
blast_furnace_slag	0.00 ... 357.38	1.00	0.00 ... 1.00	0.00 / 1.00
fly_ash	0.00 ... 200.10	1.00	0.00 ... 1.00	0.00 / 1.00
water	124.25 ... 232.65	1.00	0.00 ... 1.00	0.00 / 1.00
superplasticizer	0.00 ... 25.50	1.00	0.00 ... 1.00	0.00 / 1.00
coarse_aggregate	801.00 ... 1145.00	1.00	0.00 ... 1.00	0.00 / 1.00
fine_aggregate	594.00 ... 963.57	1.00	0.00 ... 1.00	0.00 / 1.00
concrete_compressive_stren	2.33 ... 79.77	1.00	0.00 ... 1.00	0.00 / 1.00

Tabel: rentang tiap kolom sebelum dan sesudah normalisasi (bukti hasil tiap metode)

Delapan kolom komposisi beton dinormalisasi. Karena banyak kolom sudah dimulai dari 0 (mis. fly_ash dan blast_furnace_slag), hasil Simple Feature Scaling dan Min-Max nyaris identik di kolom-kolom tersebut. Perbedaan baru terlihat pada kolom yang minimumnya jauh dari 0 seperti water dan coarse_aggregate.



Grafik: distribusi satu kolom perwakilan, asli vs tiga metode normalisasi


6. Dataset: heart.csv

Ukuran data **918 baris x 12 kolom**. Preprocessing menangani **0 sel kosong** dan meng-cap outlier pada **5 kolom kontinu**, lalu kolom-kolom itu dinormalisasi.

Kolom	Asli (min ... max)	SFS (maks)	Min-Max (min ... max)	Z (mean / std)
Age	28.00 ... 77.00	1.00	0.00 ... 1.00	0.00 / 1.00
RestingBP	90.00 ... 170.00	1.00	0.00 ... 1.00	0.00 / 1.00
Cholesterol	32.62 ... 407.62	1.00	0.00 ... 1.00	0.00 / 1.00
MaxHR	66.00 ... 202.00	1.00	0.00 ... 1.00	0.00 / 1.00
Oldpeak	-2.25 ... 3.75	1.00	0.00 ... 1.00	0.00 / 1.00

Tabel: rentang tiap kolom sebelum dan sesudah normalisasi (bukti hasil tiap metode)

Lima kolom numerik kontinu (Age, RestingBP, Cholesterol, MaxHR, Oldpeak) dinormalisasi, sedangkan kolom kategori seperti Sex dan ChestPainType sengaja dilewati karena bukan angka kontinu dan butuh encoding tersendiri. Setelah normalisasi, kelima kolom berada pada skala yang sebanding sehingga tidak ada satu pun yang mendominasi hanya karena satuannya besar.



Grafik: distribusi satu kolom perwakilan, asli vs tiga metode normalisasi

7. Kesimpulan

Ketiga metode berhasil menyeragamkan skala data, tetapi pilihannya bergantung kebutuhan. Min-Max paling intuitif ketika kita ingin semua fitur tepat berada di rentang $[0, 1]$. Simple Feature Scaling lebih sederhana namun tidak menjamin batas bawah 0. Z-Score paling tepat saat algoritma mengasumsikan data terpusat di nol atau berdistribusi normal. Yang sama pentingnya, contoh `BALANCE_FREQUENCY` menunjukkan bahwa memahami karakter data lebih menentukan daripada sekadar memilih rumus. Seluruh hasil normalisasi tersimpan di folder `output/` dengan awalan `normalisasi_`.

8. Lampiran: Output Program (Terminal)

Berikut hasil eksekusi program **normalisasi_434241079.py** langsung dari terminal, sebagai bukti bahwa seluruh proses berjalan pada ketiga dataset.

```
Windows PowerShell
PS D:\KULIAH\...\Pertemuan 3 - Data Transformation> python normalisasi_434241079.py

PROGRAM NORMALISASI DATA | NIM 434241079
Preprocessing + Normalisasi 3 metode pada 3 dataset ...

=====
CONTOH PERHITUNGAN (X = [7, 10, 15, 20, 25])
=====

```

X	Simple Feature Scaling	Min-Max	Z-Score
7.000	0.280	0.000	-1.286
10.000	0.400	0.167	-0.827
15.000	0.600	0.444	-0.061
20.000	0.800	0.722	0.704
25.000	1.000	1.000	1.470

```
=====
```

Output: contoh perhitungan & verifikasi rumus

```
Windows PowerShell

DATASET: CC GENERAL.csv
=====
Ukuran data : 8950 baris x 18 kolom

-- TAHAP 1: PREPROCESSING
Missing value ditangani : 314 sel -> 0
Outlier di-capping pada : 16 kolom kontinu

-- TAHAP 2: NORMALISASI (kolom kontinu)
Rentang data ASLI (sebelum normalisasi):

```

kolom	min	max	mean	std
BALANCE	0.000	4942.927	1390.509	1537.453
BALANCE FREQUENCY	0.722	1.000	0.932	0.111
PURCHASES	0.000	2715.873	737.149	879.486
ONEOFF PURCHASES	0.000	1443.512	354.358	511.795
INSTALLMENTS PURCHASES	0.000	1171.594	295.546	396.159
CASH ADVANCE	0.000	2784.553	672.469	998.459
PURCHASES FREQUENCY	0.000	1.000	0.490	0.401
ONEOFF PURCHASES FREQUE	0.000	0.750	0.185	0.256
PURCHASES INSTALLMENTS	0.000	1.000	0.364	0.397
CASH ADVANCE FREQUENCY	0.000	0.556	0.126	0.173
CASH ADVANCE TRX	0.000	10.000	2.383	3.418
PURCHASES TRX	0.000	41.000	11.624	13.041
CREDIT LIMIT	50.000	13850.000	4419.137	3383.600
PAYMENTS	0.000	4177.922	1347.084	1272.735
MINIMUM PAYMENTS	0.019	1715.497	556.752	532.144
PRC_FULL_PAYMENT	0.000	0.357	0.087	0.139

```

1) Simple Feature Scaling (harusnya max = 1):

```

kolom	min	max	mean	std
BALANCE	0.000	1.000	0.281	0.311
BALANCE FREQUENCY	0.722	1.000	0.932	0.111
PURCHASES	0.000	1.000	0.271	0.324
ONEOFF PURCHASES	0.000	1.000	0.245	0.355
INSTALLMENTS PURCHASES	0.000	1.000	0.252	0.338
CASH ADVANCE	0.000	1.000	0.241	0.359
PURCHASES FREQUENCY	0.000	1.000	0.490	0.401
ONEOFF PURCHASES FREQUE	0.000	1.000	0.246	0.341
PURCHASES INSTALLMENTS	0.000	1.000	0.364	0.397
CASH ADVANCE FREQUENCY	0.000	1.000	0.227	0.311
CASH ADVANCE TRX	0.000	1.000	0.238	0.342
PURCHASES TRX	0.000	1.000	0.284	0.318
CREDIT LIMIT	0.004	1.000	0.319	0.244
PAYMENTS	0.000	1.000	0.322	0.305
MINIMUM PAYMENTS	0.000	1.000	0.325	0.310
PRC_FULL_PAYMENT	0.000	1.000	0.244	0.388

Output CC GENERAL.csv — preprocessing, data asli, Simple Feature Scaling

```

Windows PowerShell + - □ ×

2) Min-Max Normalization (harusnya min=0, max=1):
kolom      min      max      mean      std
BALANCE    0.000    1.000    0.281    0.311
BALANCE FREQUENCY  0.000    1.000    0.754    0.400
PURCHASES  0.000    1.000    0.271    0.324
ONEOFF PURCHASES  0.000    1.000    0.245    0.355
INSTALLMENTS PURCHASES  0.000    1.000    0.252    0.338
CASH ADVANCE  0.000    1.000    0.241    0.359
PURCHASES FREQUENCY  0.000    1.000    0.490    0.401
ONEOFF PURCHASES FREQUE  0.000    1.000    0.246    0.341
PURCHASES INSTALLMENTS  0.000    1.000    0.364    0.397
CASH ADVANCE FREQUENCY  0.000    1.000    0.227    0.311
CASH ADVANCE TRX  0.000    1.000    0.238    0.342
PURCHASES TRX  0.000    1.000    0.284    0.318
CREDIT LIMIT  0.000    1.000    0.317    0.245
PAYMENTS     0.000    1.000    0.322    0.305
MINIMUM PAYMENTS  0.000    1.000    0.325    0.310
PRC_FULC_PAYMENT  0.000    1.000    0.244    0.388

3) Z-Score Standardization (harusnya mean=0, std=1):
kolom      min      max      mean      std
BALANCE    -0.904    2.311    0.000    1.000
BALANCE FREQUENCY  -1.887    0.616    0.000    1.000
PURCHASES  -0.838    2.250    0.000    1.000
ONEOFF PURCHASES  -0.692    2.128    0.000    1.000
INSTALLMENTS PURCHASES  -0.746    2.211    0.000    1.000
CASH ADVANCE  -0.674    2.115    0.000    1.000
PURCHASES FREQUENCY  -1.222    1.270    0.000    1.000
ONEOFF PURCHASES FREQUE  -0.723    2.211    0.000    1.000
PURCHASES INSTALLMENTS  -0.917    1.599    0.000    1.000
CASH ADVANCE FREQUENCY  -0.730    2.487    0.000    1.000
CASH ADVANCE TRX  -0.697    2.229    0.000    1.000
PURCHASES TRX  -0.891    2.253    0.000    1.000
CREDIT LIMIT  -1.291    2.787    0.000    1.000
PAYMENTS    -1.058    2.224    0.000    1.000
MINIMUM PAYMENTS  -1.046    2.178    0.000    1.000
PRC_FULC_PAYMENT  -0.629    1.947    0.000    1.000

Hasil disimpan -> output/normalisasi_[sfs|minmax|zscore]_CC GENERAL.csv
Grafik        -> output/normalisasi_CC GENERAL.png

=====

```

Output CC GENERAL.csv — Min-Max & Z-Score


```

Windows PowerShell
+

DATASET: concrete_data.csv
=====
Ukuran data : 1030 baris x 9 kolom

-- TAHAP 1: PREPROCESSING
Missing value ditangani : 0 sel -> 0
Outlier di-capping pada : 8 kolom kontinu

-- TAHAP 2: NORMALISASI (kolom kontinu)
Rentang data ASLI (sebelum normalisasi):
  kolom      min      max      mean      std
cement      102.000    540.000    281.168    104.456
blast_furnace_slag  0.000    357.375     73.892     86.224
fly_ash      0.000    200.100     54.188     63.966
water       124.250    232.650    181.543     21.215
superplasticizer  0.000     25.500      6.159       5.800
coarse aggregate 801.000   1145.000    972.919     77.716
fine aggregate  594.000    963.575    773.440     79.777
concrete_compressive_st 2.330     79.773     35.813     16.683

1) Simple Feature Scaling (harusnya max = 1):
  kolom      min      max      mean      std
cement      0.189     1.000     0.521     0.193
blast_furnace_slag  0.000     1.000     0.207     0.241
fly_ash      0.000     1.000     0.271     0.320
water       0.534     1.000     0.780     0.091
superplasticizer  0.000     1.000     0.242     0.227
coarse aggregate  0.700     1.000     0.850     0.068
fine aggregate  0.616     1.000     0.803     0.083
concrete_compressive_st 0.029     1.000     0.449     0.209

2) Min-Max Normalization (harusnya min=0, max=1):
  kolom      min      max      mean      std
cement      0.000     1.000     0.409     0.238
blast_furnace_slag  0.000     1.000     0.207     0.241
fly_ash      0.000     1.000     0.271     0.320
water       0.000     1.000     0.529     0.196
superplasticizer  0.000     1.000     0.242     0.227
coarse aggregate  0.000     1.000     0.500     0.226
fine aggregate  0.000     1.000     0.486     0.216
concrete_compressive_st 0.000     1.000     0.432     0.215

3) Z-Score Standardization (harusnya mean=0, std=1):
  kolom      min      max      mean      std
cement     -1.715     2.478     0.000     1.000
blast_furnace_slag -0.857     3.288     0.000     1.000
fly_ash     -0.847     2.281     0.000     1.000
water      -2.701     2.409     0.000     1.000
superplasticizer -1.062     3.335     0.000     1.000
coarse aggregate -2.212     2.214     0.000     1.000
fine aggregate  -2.249     2.383     0.000     1.000
concrete_compressive_st -2.007     2.635     0.000     1.000

Hasil disimpan -> output/normalisasi_[sfs|minmax|zscore]_concrete_data.csv
Grafik          -> output/normalisasi_concrete_data.png
=====

```

Output concrete_data.csv

```
Windows PowerShell + - □ ×

DATASET: heart.csv
=====
Ukuran data : 918 baris x 12 kolom

-- TAHAP 1: PREPROCESSING
Missing value ditangani : 0 sel -> 0
Outlier di-capping pada : 5 kolom kontinu

-- TAHAP 2: NORMALISASI (kolom kontinu)
Rentang data ASLI (sebelum normalisasi):
      kolom      min      max      mean      std
Age           28.000    77.000    53.511     9.427
RestingBP     90.000   170.000   132.125    16.984
Cholesterol   32.625   407.625   203.985    95.870
MaxHR         66.000   202.000   136.819    25.418
Oldpeak       -2.250     3.750     0.878     1.031

1) Simple Feature Scaling (harusnya max = 1):
      kolom      min      max      mean      std
Age           0.364     1.000     0.695     0.122
RestingBP     0.529     1.000     0.777     0.100
Cholesterol   0.080     1.000     0.500     0.235
MaxHR         0.327     1.000     0.677     0.126
Oldpeak       -0.600     1.000     0.234     0.275

2) Min-Max Normalization (harusnya min=0, max=1):
      kolom      min      max      mean      std
Age           0.000     1.000     0.521     0.192
RestingBP     0.000     1.000     0.527     0.212
Cholesterol   0.000     1.000     0.457     0.256
MaxHR         0.000     1.000     0.521     0.187
Oldpeak       0.000     1.000     0.521     0.172

3) Z-Score Standardization (harusnya mean=0, std=1):
      kolom      min      max      mean      std
Age          -2.706     2.492     0.000     1.000
RestingBP    -2.480     2.230     0.000     1.000
Cholesterol  -1.787     2.124     0.000     1.000
MaxHR        -2.786     2.564     0.000     1.000
Oldpeak      -3.033     2.786     0.000     1.000

Hasil disimpan -> output/normalisasi [sfs|minmax|zscore]_heart.csv
Grafik          -> output/normalisasi_heart.png

=====
SELESAI - Semua dataset telah dinormalisasi.
=====
```

Output heart.csv