

LAPORAN TUGAS

SELEKSI FITUR

Mata Kuliah Machine Learning

Pertemuan 4



NAMA: Muhammad Irfan Nuha

NIM: 434241079

Kelas: TI-C5

1. Pendahuluan

Tidak semua kolom dalam sebuah dataset berguna untuk model. Ada fitur yang benar-benar berhubungan dengan apa yang ingin diprediksi, ada pula yang sekadar menambah beban tanpa memberi informasi. Seleksi fitur bertujuan menyaring kolom mana yang layak dipakai. Laporan ini melakukan seleksi fitur pada dataset **heart.csv** (918 baris) yang bertujuan memprediksi **HeartDisease** (0 = tidak sakit jantung, 1 = sakit). Karena dataset ini punya fitur bertipe kategorikal sekaligus numerik, dipakai dua uji yang berbeda sesuai jenis datanya.

2. Metode Seleksi Fitur

Pemilihan uji mengikuti jenis fitur, seperti diajarkan di modul:

Chi-Square dipakai untuk **fitur kategorikal**. Uji ini membandingkan tabel kontingensi (crosstab) antara fitur dan target, lalu mengukur apakah sebarannya berbeda dari yang diharapkan bila keduanya tidak berhubungan.

Independent t-test dipakai untuk **fitur numerik**. Karena target hanya punya dua kelas, tiap fitur numerik diuji apakah rata-ratanya berbeda signifikan antara kelas 0 dan kelas 1. (Jika target punya lebih dari dua kelas, uji yang tepat adalah ANOVA.)

Aturan keputusannya sama untuk keduanya: bila **p-value < 0,05**, fitur dianggap punya hubungan signifikan dengan target sehingga **dipilih**; bila tidak, fitur **dibuang**.

```
from scipy.stats import chi2_contingency # untuk fitur kategorikal
from scipy.stats import ttest_ind       # untuk fitur numerik
```

3. Chi-Square (Fitur Kategorikal)

Enam fitur kategorikal diuji terhadap target HeartDisease memakai tabel kontingensi (**pd.crosstab**) lalu **chi2_contingency**. Hasilnya:

Fitur	Chi-Square	DOF	P-Value	Keputusan
ST Slope	355.92	2	5.168e-78	Dipilih
ChestPainType	268.07	3	8.084e-58	Dipilih
ExerciseAngina	222.26	1	2.908e-50	Dipilih
Sex	84.15	1	4.598e-20	Dipilih
FastingBS	64.32	1	1.057e-15	Dipilih
RestingECG	10.93	2	4.229e-03	Dipilih

Tabel 1. Hasil uji Chi-Square (diurutkan dari paling signifikan)

Enam fitur kategorikal diuji terhadap HeartDisease. Semuanya menghasilkan p-value jauh di bawah 0,05, jadi keenamnya relevan. Yang paling kuat hubungannya adalah **ST_Slope** dan **ChestPainType** dengan nilai Chi-Square tertinggi (355,9 dan 268,1) — masuk akal secara medis karena bentuk segmen ST dan tipe nyeri dada memang penanda penting penyakit jantung. RestingECG paling lemah namun tetap signifikan ($p = 0,004$).

```
Windows PowerShell + - □ ×
PS D:\KULIAH\...\Pertemuan 4 - Seleksi Fitur> python seleksi_fitur_chisquare_434241079.py

=====
SELEKSI FITUR - CHI-SQUARE (fitur kategorikal)
=====
Dataset : heart.csv (918 baris x 12 kolom)
Target : HeartDisease | alpha = 0.05

Fitur      Chi-Square      P-Value      Keputusan
-----
ST Slope   355.92      5.168e-78    Dipilih (signifikan)
ChestPainType 268.07      8.084e-58    Dipilih (signifikan)
ExerciseAngina 222.26      2.908e-50    Dipilih (signifikan)
Sex         84.15       4.598e-20    Dipilih (signifikan)
FastingBS   64.32       1.057e-15    Dipilih (signifikan)
RestingECG  10.93       4.229e-03    Dipilih (signifikan)

Fitur kategorikal terpilih (p < 0.05):
ST_Slope, ChestPainType, ExerciseAngina, Sex, FastingBS, RestingECG

Hasil disimpan -> hasil_seleksi_chisquare.csv
```

Screenshot output program Chi-Square

4. Independent t-test (Fitur Numerik)

Lima fitur numerik diuji dengan `ttest_ind` (Welch) membandingkan rata-rata tiap fitur antara kelas 0 dan kelas 1. Hasilnya:

Fitur	Mean K0	Mean K1	t-stat	P-Value	Keputusan
Oldpeak	0.41	1.27	-14.04	1.903e-40	Dipilih
MaxHR	148.15	127.66	13.23	1.431e-36	Dipilih
Age	50.55	55.90	-8.82	6.348e-18	Dipilih
Cholesterol	227.12	175.94	7.63	6.481e-14	Dipilih
RestingBP	130.18	134.19	-3.34	8.732e-04	Dipilih

Tabel 2. Hasil uji t-test (diurutkan dari paling signifikan)

Lima fitur numerik diuji dengan membandingkan reratanya antara pasien sehat (kelas 0) dan sakit (kelas 1). Semua fitur signifikan. Perbedaan paling tajam ada pada **Oldpeak** dan **MaxHR**: pasien sakit cenderung punya Oldpeak jauh lebih tinggi (1,27 vs 0,41) dan MaxHR lebih rendah (127,7 vs 148,2). Menariknya rata-rata Cholesterol kelas sakit justru lebih rendah, ini efek dari banyaknya nilai Cholesterol yang tercatat 0 (data tak terukur) pada sebagian pasien, jadi angkanya perlu dibaca dengan hati-hati meski uji tetap menyatakannya signifikan.

```
Windows PowerShell +
PS D:\KULIAH\...\Pertemuan 4 - Seleksi Fitur> python seleksi_fitur_ttest_434241079.py

=====
SELEKSI FITUR - INDEPENDENT t-TEST (fitur numerik)
=====
Dataset : heart.csv (918 baris x 12 kolom)
Target : HeartDisease | alpha = 0.05

Jumlah data -> kelas 0 (sehat): 410 | kelas 1 (sakit): 508

Fitur      Mean_0  Mean_1  t-stat  P-Value  Keputusan
-----
Oldpeak    0.41    1.27    -14.04   1.903e-40  Dipilih (signifikan)
MaxHR      148.15  127.66  13.23    1.431e-36  Dipilih (signifikan)
Age        50.55   55.90   -8.82    6.348e-18  Dipilih (signifikan)
Cholesterol 227.12  175.94   7.63    6.481e-14  Dipilih (signifikan)
RestingBP  130.18  134.19  -3.34    8.732e-04  Dipilih (signifikan)

Fitur numerik terpilih (p < 0.05):
  Oldpeak, MaxHR, Age, Cholesterol, RestingBP

Hasil disimpan -> hasil_seleksi_ttest.csv
```

Screenshot output program t-test

5. Kesimpulan

Pada dataset heart.csv, **seluruh 11 fitur** (6 kategorikal + 5 numerik) yang diuji ternyata signifikan ($p < 0,05$), sehingga semuanya layak dipertahankan untuk pemodelan. Hal ini wajar karena kolom-kolom pada dataset ini memang sudah dipilih sebagai indikator medis penyakit jantung. Yang lebih penting dari sekadar hasilnya adalah penerapan metodenya: Chi-Square untuk kategorikal dan t-test untuk numerik, dengan p-value sebagai dasar keputusan. Hasil lengkap kedua uji disimpan pada `hasil_seleksi_chisquare.csv` dan `hasil_seleksi_ttest.csv`.