

LAPORAN TUGAS EKSTRAKSI FITUR (PCA)

Mata Kuliah Machine Learning – Pertemuan 5

NAMA : Muhammad Irfan Nuha

NIM : 434241079

Kelas : TI-C5

Tugas Individu

1. Pendahuluan

Kalau seleksi fitur (tugas sebelumnya) **memilih** kolom asli yang penting, maka **ekstraksi fitur** berbeda: ia **membentuk fitur baru** hasil kombinasi dari fitur lama. Metode yang dipakai di sini adalah **PCA (Principal Component Analysis)**. PCA memampatkan banyak fitur menjadi sedikit **komponen utama** (PC1, PC2, ...) yang berupa arah dengan sebaran (varians) terbesar dalam data. Tujuannya mengurangi dimensi data sambil mempertahankan sebanyak mungkin informasinya. Laporan ini menerapkan PCA pada dataset **heart.csv** dalam dua skenario: jumlah komponen **bebas** dan jumlah komponen **optimal**.

2. Metode PCA

Langkah PCA mengikuti contoh pada modul:

1. Pisahkan fitur (X) dari target (**HeartDisease**).
2. **Encode** kolom kategorikal (Sex, ChestPainType, dll.) menjadi angka dengan LabelEncoder, karena PCA hanya bisa mengolah angka. Setelah encoding didapat **11 fitur**.
3. **Standarisasi** dengan StandardScaler. Ini wajib karena PCA sensitif terhadap skala; kolom berangka besar akan mendominasi bila tidak disamakan dulu.
4. Terapkan **PCA** lalu baca **explained variance ratio**, yaitu persentase informasi (varians) yang dijelaskan tiap komponen.


```
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.decomposition import PCA
```

3. Skenario 1: Jumlah Komponen Bebas (n = 2)

Pada skenario ini jumlah komponen dipilih **bebas = 2**, mengikuti contoh modul, supaya hasilnya bisa digambar dalam scatter plot 2 dimensi. PC1 menjelaskan **25,14%** varians dan PC2 **13,31%**, sehingga total hanya **38,45%** informasi yang dipertahankan dan sekitar 61,55% hilang. Wajar, karena meringkas 11 fitur menjadi hanya 2 pasti kehilangan banyak detail. Meski begitu, plot tetap berguna untuk melihat sebaran dan kecenderungan pemisahan antara pasien sehat (0) dan sakit (1).

Komponen	Varians Dijelaskan
PC1	25.14%
PC2	13.31%
Total	38.45%

Tabel 1. Varians yang dijelaskan 2 komponen



Gambar 1. Scatter PC1 vs PC2 diwarnai HeartDisease

```
Windows PowerShell +
PS D:\KULIAH\...\Pertemuan 5 - Ekstraksi Fitur> python ekstraksi_fitur_pca_bebas_434241079.py

=====
EKSTRAKSI FITUR - PCA (n komponen BEBAS = 2)
=====
Dataset : heart.csv (918 baris x 12 kolom)
Jumlah fitur setelah encoding : 11

Explained Variance Ratio:
PC1 : 25.14%
PC2 : 13.31%
Total Variance Explained (2 komponen): 38.45%
Informasi yang hilang: 61.55%

5 baris pertama hasil PCA:
PC1      PC2      HeartDisease
2.261181  0.169797    0
1.137621  1.097544    1
1.101846 -1.167057    0
-0.980703 1.113893    1
1.046800 -0.395467    0

Hasil disimpan -> hasil_pca_bebas.csv
Grafik          -> output/pca_bebas_scatter.png
```


Screenshot output program PCA (n bebas)

4. Skenario 2: Jumlah Komponen Optimal (ambang 95%)

Pada skenario ini jumlah komponen ditentukan secara **optimal**, yaitu jumlah terkecil yang varians kumulatifnya sudah mencapai **95%**. Dari scree plot, ambang 95% baru tercapai pada **10 komponen** (96,29% varians). Artinya untuk mempertahankan 95% informasi, data 11 fitur hanya bisa diringkas menjadi 10 komponen. Ini sekaligus temuan menarik: fitur-fitur heart.csv **relatively independen** (tidak saling berkorelasi kuat), sehingga tiap komponen hanya menyumbang sedikit varians dan PCA tidak bisa memampatkan data secara agresif. Beda halnya bila fiturnya banyak yang berkorelasi — PCA akan mengompres jauh lebih banyak.

Komponen	Varians	Kumulatif
PC1	25.14%	25.14%
PC2	13.31%	38.45%
PC3	10.51%	48.96%
PC4	9.09%	58.05%
PC5	7.92%	65.97%
PC6	7.70%	73.66%
PC7	7.33%	81.00%
PC8	5.68%	86.67%
PC9	5.07%	91.74%
PC10	4.56%	96.29%
PC11	3.71%	100.00%

Tabel 2. Varians tiap komponen dan kumulatifnya ($n_{\text{optimal}} = 10$)



Gambar 2. Scree plot & varians kumulatif dengan ambang 95%

```
Windows PowerShell + - □ ×
PS D:\KULIAH\...\Pertemuan 5 - Ekstraksi Fitur> python ekstraksi_fitur_pca_optimal_434241079.py

=====
EKSTRAKSI FITUR - PCA (n komponen OPTIMAL, ambang 95%)
=====
Dataset : heart.csv (918 baris x 12 kolom)
Jumlah fitur setelah encoding : 11

Komponen    Varians    Kumulatif
-----
PC1          25.14%     25.14%
PC2          13.31%     38.45%
PC3          10.51%     48.96%
PC4           9.09%     58.05%
PC5           7.92%     65.97%
PC6           7.70%     73.66%
PC7           7.33%     81.00%
PC8           5.68%     86.67%
PC9           5.07%     91.74%
PC10          4.56%     96.29%
PC11          3.71%    100.00%

n komponen optimal (>= 95% varians) : 10 dari 11 fitur asli
Varians dipertahankan : 96.29%

5 baris pertama hasil PCA optimal:
      PC1      PC2      PC3      PC4      PC5      PC6      PC7      PC8      PC9      PC10  HeartDisease
2.261181  0.169797 -0.451569  0.399556  1.350563  0.157335  0.683548 -0.042348 -0.028407 -0.254713      0
1.137621  1.097544  1.416047  0.396701 -0.652823  1.274868 -0.181768 -1.516715  0.363428 -0.720587      1
1.101846 -1.167057 -0.858293  1.865065  0.655026  0.195717 -0.381443  0.816281  0.887387 -1.155705      0
-0.980703  1.113893 -0.679560  1.101481 -1.690267  0.083224  0.202347 -0.878129  0.887688 -0.048640      1
1.046800 -0.395467  1.146740  0.682775  1.123703 -0.501264 -0.965965 -0.126835  0.379485 -0.280452      0

Hasil disimpan -> hasil_pca_optimal.csv
Grafik          -> output/pca_optimal_scee.png
```

Screenshot output program PCA (n optimal)

5. Kesimpulan

Kedua skenario menunjukkan cara kerja PCA sekaligus batasannya. Dengan **2 komponen** data mudah divisualisasikan tetapi hanya 38% informasi tersisa; dengan **jumlah optimal (10 komponen)** hampir seluruh informasi (96%) dipertahankan namun reduksi dimensinya kecil. Pilihan jumlah komponen selalu merupakan **tradeoff antara kesederhanaan dan informasi yang dipertahankan**. Hasil kedua skenario disimpan pada **hasil_pca_bebas.csv** dan **hasil_pca_optimal.csv**.