

# **LAPORAN TUGAS IMBALANCED DATA**

Mata Kuliah Machine Learning – Pertemuan 6

---

**NAMA : Muhammad Irfan Nuha**

**NIM : 434241079**

**Kelas : TI-C5**

Tugas Individu


---

## 1. Pendahuluan

Data dikatakan **imbalanced** (tidak seimbang) ketika jumlah data antar kelas target berbeda jauh. Masalahnya, model machine learning cenderung “berpihak” pada kelas mayoritas dan mengabaikan kelas minoritas, padahal sering kali justru kelas minoritas yang penting (mis. pasien sakit, transaksi penipuan). Laporan ini menangani ketidakseimbangan pada dataset **heart** yang sudah melewati tahap preprocessing (handling missing value + capping outlier pada Pertemuan 2), dengan target HeartDisease, menggunakan empat metode: SMOTE, SMOTE-ENN, ROS, dan RUS.

## 2. Kondisi Awal Dataset

Dataset yang dipakai adalah **heart\_preprocessed.csv**, yaitu heart.csv yang sudah dibersihkan pada tugas preprocessing (Pertemuan 2), namun belum diseleksi maupun diekstraksi fiturnya. Sebelum penyeimbangan, dataset memiliki **410** data kelas 0 (Tidak Sakit) dan **508** data kelas 1 (Sakit) — sekitar 45% : 55%. Ketimpangannya tergolong ringan, tetapi tetap bisa dipakai untuk mendemonstrasikan cara kerja keempat metode. Karena metode resampling hanya menerima angka, kolom kategorikal (Sex, ChestPainType, dll.) di-encode dulu menjadi angka.



Gambar 1. Distribusi kelas sebelum penyeimbangan

## 3. Metode Penyeimbangan

Empat metode yang digunakan terbagi dua kelompok:

**Oversampling** (menambah data kelas minoritas):

- **SMOTE** (Synthetic Minority Over-sampling Technique): membuat data sintetis baru untuk kelas minoritas dengan cara interpolasi di antara tetangga terdekatnya — bukan sekadar menggandakan.
- **ROS** (Random Over Sampling): menggandakan data kelas minoritas secara acak sampai seimbang. Sederhana, tapi berisiko overfitting karena datanya duplikat.

**Undersampling / kombinasi** (mengurangi data):

- **RUS** (Random Under Sampling): membuang sebagian data kelas mayoritas secara acak sampai

seimbang. Cepat, tapi berisiko kehilangan informasi.

- **SMOTE-ENN**: kombinasi SMOTE (menambah) lalu **ENN** (Edited Nearest Neighbours) yang membersihkan data yang ambigu/berdekatan dengan kelas lain. Hasilnya lebih bersih dan sering berjumlah lebih sedikit dari data asli.


```
from imblearn.over_sampling import SMOTE, RandomOverSampler
from imblearn.under_sampling import RandomUnderSampler
from imblearn.combine import SMOTEENN
```

## 4. Hasil

Tabel dan grafik berikut merangkum jumlah data tiap kelas sebelum dan sesudah tiap metode:

| Metode    | Kelas 0 | Kelas 1 | Total |
|-----------|---------|---------|-------|
| AWAL      | 410     | 508     | 918   |
| SMOTE     | 508     | 508     | 1016  |
| SMOTE-ENN | 201     | 204     | 405   |
| ROS       | 508     | 508     | 1016  |
| RUS       | 410     | 410     | 820   |

Tabel 1. Jumlah data tiap kelas sebelum & sesudah tiap metode




Gambar 2. Perbandingan distribusi kelas antar metode


Dari hasilnya terlihat jelas perbedaan cara kerja tiap metode:

- **SMOTE** dan **ROS** menyamakan kelas minoritas (410) naik ke 508, sehingga total data bertambah menjadi 1016. Bedanya, SMOTE membuat data sintetis baru sedangkan ROS menggandakan yang sudah ada.
- **RUS** menyamakan dengan menurunkan kelas mayoritas (508) ke 410, total menyusut jadi 820.
- **SMOTE-ENN** paling agresif memangkas: setelah menambah lalu membersihkan data ambigu, total tinggal 405 (201 vs 204) — lebih sedikit tapi lebih “bersih” dan tetap seimbang.


## 5. Distribusi Tiap Metode




*SMOTE — 508 : 508*



*SMOTE-ENN — 201 : 204*



*ROS — 508 : 508*



*RUS — 410 : 410*

## 6. Output Program

```
Windows PowerShell
PS D:\KULIAH\...\Pertemuan 6 - Imbalanced Data> python imbalanced_data_434241079.py

=====
IMBALANCED DATA - heart_preprocessed.csv
=====
Ukuran data : 918 baris x 12 kolom

Distribusi AWAL (sebelum penyeimbangan):
Kelas 0 (Tidak Sakit): 410
Kelas 1 (Sakit): 508

Distribusi SESUDAH SMOTE:
Kelas 0 (Tidak Sakit): 508
Kelas 1 (Sakit): 508
Total baris: 1016

Distribusi SESUDAH SMOTE-ENN:
Kelas 0 (Tidak Sakit): 201
Kelas 1 (Sakit): 204
Total baris: 405

Distribusi SESUDAH ROS:
Kelas 0 (Tidak Sakit): 508
Kelas 1 (Sakit): 508
Total baris: 1016

Distribusi SESUDAH RUS:
Kelas 0 (Tidak Sakit): 410
Kelas 1 (Sakit): 410
Total baris: 820

=====
RINGKASAN JUMLAH DATA TIAP METODE
=====
Metode  Kelas 0  Kelas 1  Total
AWAL      410      508      918
SMOTE      508      508     1016
SMOTE-ENN  201      204      405
ROS        508      508     1016
RUS        410      410      820

Grafik distribusi tersimpan di folder output/
```

*Screenshot hasil run program di terminal*

## 7. Kesimpulan

Keempat metode berhasil menyeimbangkan kelas, namun dengan konsekuensi berbeda. Oversampling (SMOTE, ROS) menjaga seluruh data mayoritas tetapi memperbesar ukuran data; undersampling (RUS) menyederhanakan data tetapi membuang informasi; SMOTE-ENN memberi data paling bersih tetapi jumlahnya paling sedikit. Pemilihan metode bergantung pada seberapa besar data dan seberapa penting mempertahankan seluruh sampel mayoritas. Untuk data yang benar-benar timpang, SMOTE atau SMOTE-ENN umumnya menjadi pilihan yang lebih baik daripada sekadar menggandakan atau membuang data.